

Estatística Aplicada

Prof. Carlos Cesar Cavalcante Dias

Programa

- ❑ Variáveis
- ❑ População e Amostra
- ❑ Distribuição de Frequência
- ❑ Representação Gráfica
- ❑ Medidas de Tendência Central
- ❑ Medidas de Variabilidade
- ❑ BOXPLOT
- ❑ Distribuição Normal
- ❑ Estimação
- ❑ Teste de hipótese
- ❑ Análise Bivariada

Plano de Aula

CRITÉRIO DE AVALIAÇÃO
(P1 + P2 + Exercícios) / 3

P1 = Prova Bimestral

P2 = Prova Semestral

Exercícios = Listas Feitas.

Estatística Aplicada

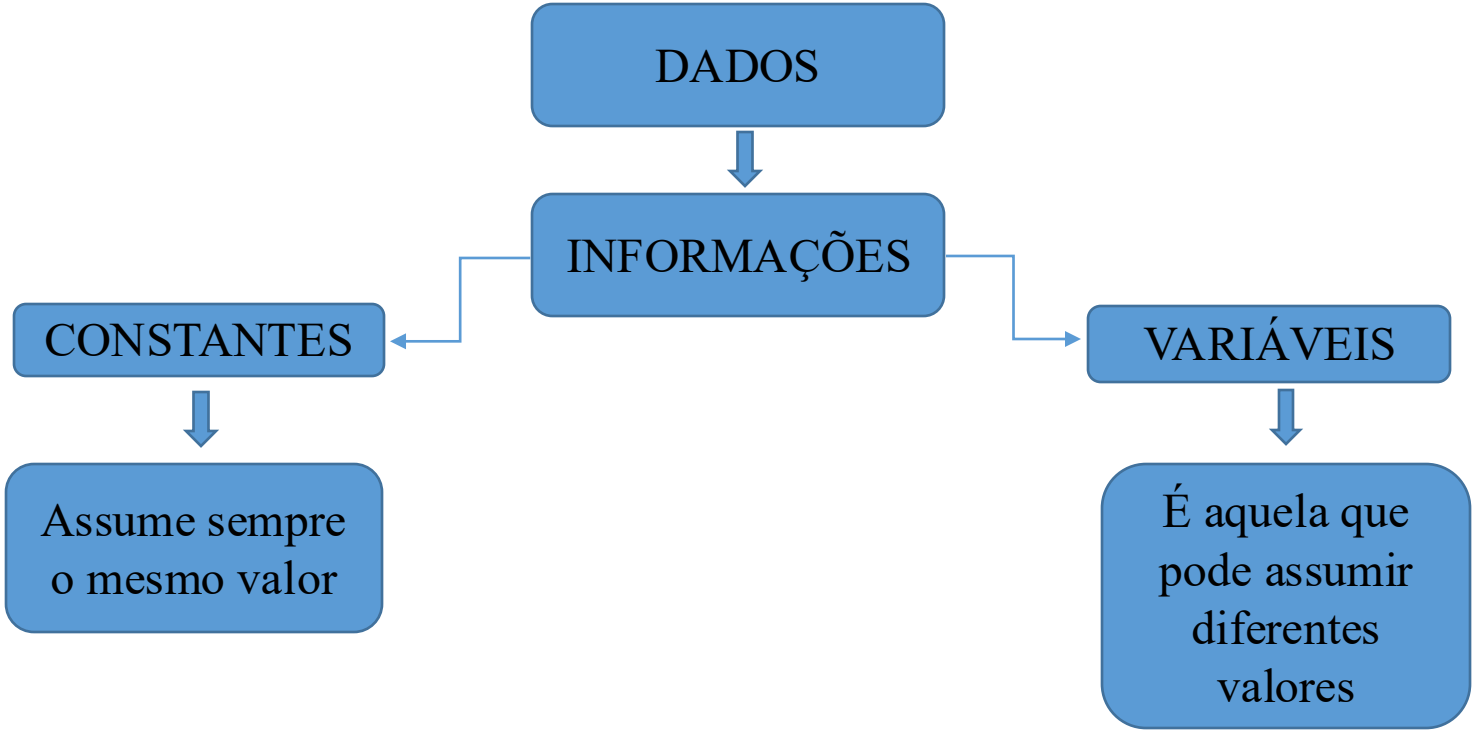


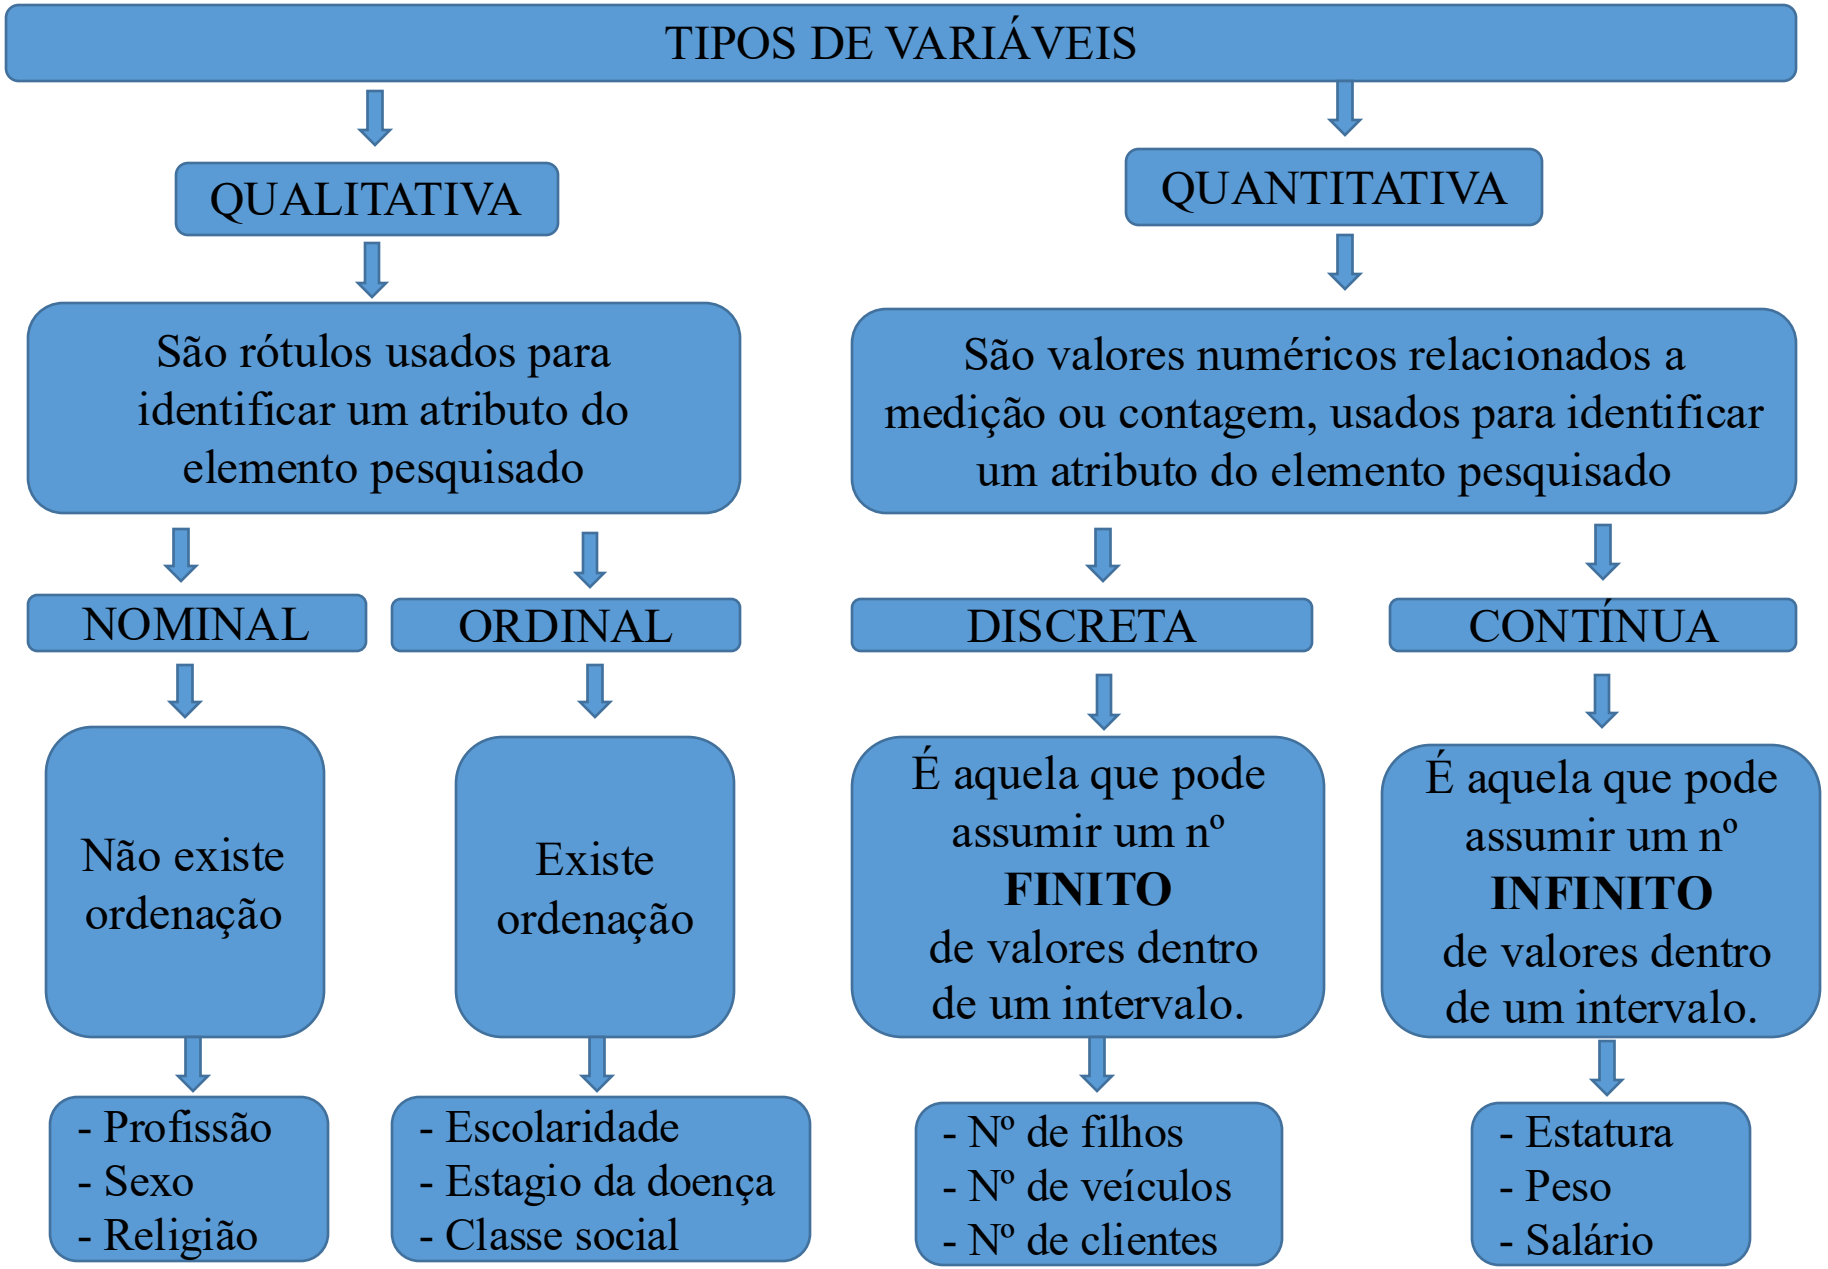
Conjunto de métodos apropriados à coleta, organização, resumo, descrição, análise e interpretação de **DADOS** observados, tendo como objetivo a compreensão de uma realidade específica para a tomada da decisão.

Os métodos são utilizados para compilação e análise de uma pesquisa

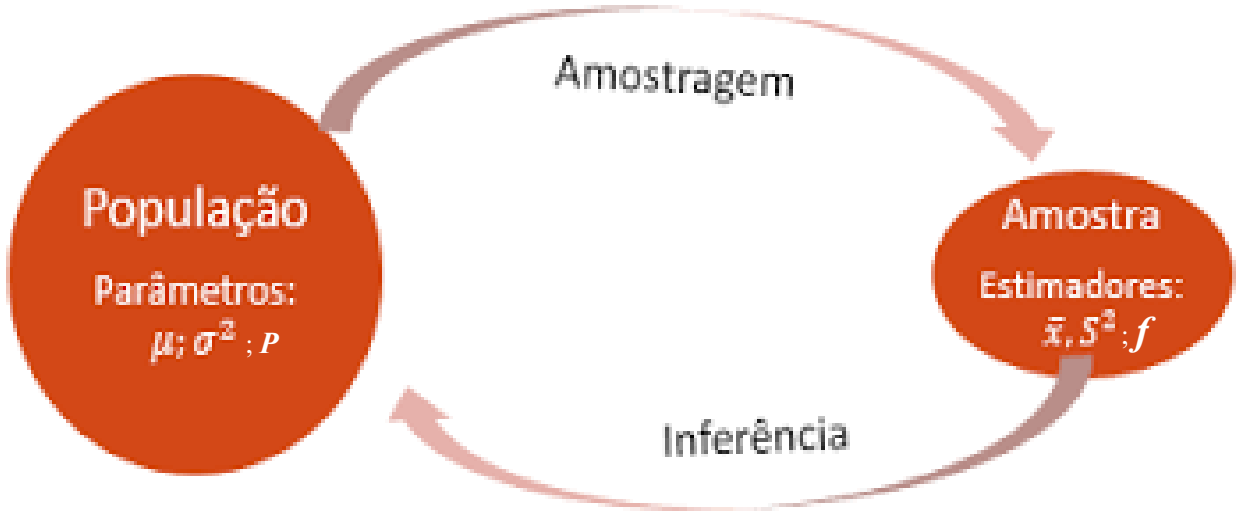


Pesquisa é toda ação que tem como objetivo a aquisição de conhecimentos a fim de solucionar algum problema.


DADOS
INFORMAÇÕES
CONSTANTES
VARIÁVEIS
Assume sempre o mesmo valor
É aquela que pode assumir diferentes valores


TIPOS DE VARIÁVEIS
QUALITATIVA
QUANTITATIVA
São rótulos usados para identificar um atributo do elemento pesquisado
São valores numéricos relacionados a medição ou contagem, usados para identificar um atributo do elemento pesquisado
NOMINAL
ORDINAL
DISCRETA
CONTÍNUA
Não existe ordenação
Existe ordenação
É aquela que pode assumir um nº FINITO de valores dentro de um intervalo.
É aquela que pode assumir um nº INFINITO de valores dentro de um intervalo.
- Profissão
- Sexo
- Religião
- Escolaridade
- Estagio da doença
- Classe social
- Nº de filhos
- Nº de veículos
- Nº de clientes
- Estatura
- Peso
- Salário

ELEMENTOS BÁSICOS PARA RELIZAÇÃO DE UMA PESQUISA



População:

Conjunto de elementos que possuem característica comuns, sendo elas de interesse do estudo a ser realizado

Parâmetros:

São medidas que caracterizam uma população.

Amostra

É uma parte da população, devendo ser representativa.

Estimadores:

São medidas que caracterizam uma amostra.

Estatística Descritiva

Tem como objetivo analisar, representar
e sintetizar os dados observados através de:



Medidas
Descritivas

Exemplo de Estatística Descritiva

Estatística Descritiva

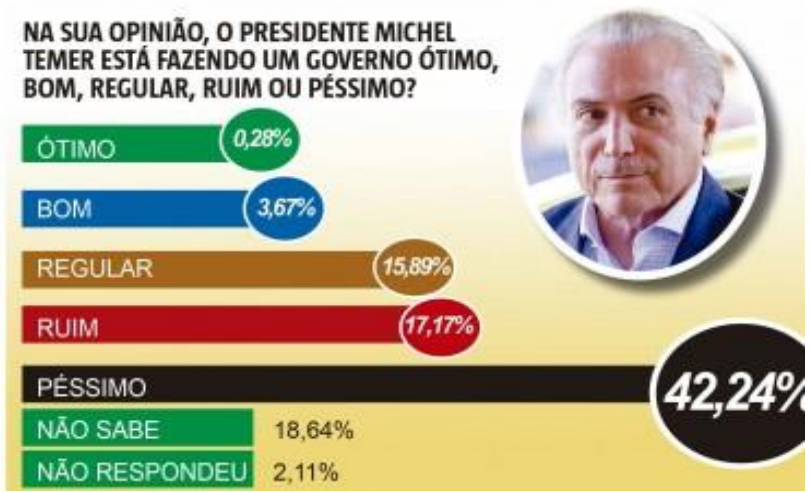
O que fazer com as observações que coletamos?



Primeira Etapa:

Resumo dos dados = Estatística descritiva

7



Síntese dos dados

Distribuição de Frequência

TITULO		
X(un.)	F	F%
Σ		

X = variável de interesse

(un.) = Unidade da variável

F = Frequência absoluta = nº de vezes que o valor se repete no conjunto de dados

F% = Frequência relativa

Síntese dos dados

Distribuição de Frequência

A escola aplicou um questionário aos alunos a fim de saber o que eles acham da comida apresentada, obtendo as seguintes respostas: Excelente, Ótimo, Bom, Médio e Fraco.

B	O	O	E	E	E	E	M	B	O	F	B	M	B	M	E	E	M
O	E	E	E	E	O	E	E	O	B	E	B	M	E	B	E	B	O
E	O	O	E	B	F	E	O	M	E	E	M	O	B	M	E	O	F

TITULO		
X(un.)	F	F%
Σ		

Qualidade da Comida		
Conceito	F	F%
E	21	38,89
O	12	22,22
B	10	18,52
M	8	14,81
F	3	5,56
Σ	54	100,00

Síntese dos dados

Distribuição de Frequência

Os dados a seguir referem-se ao tempo gasto com auditoria , medido em dias, em uma amostra de 30 empresas.

23	21	20	22	14	14	15	27	21	23	19	18	22	32	21
18	22	23	28	12	23	26	27	19	25	17	20	17	23	18

TITULO		
X(un.)	F	F%
Σ		

Tempo (dias)	F	F%
12	1	3,33
14	2	6,67
15	1	3,33
17	2	6,67
18	3	10,00
19	2	6,67
20	2	6,67
21	3	10,00
22	3	10,00
23	5	16,67
25	1	3,33
26	1	3,33
27	2	6,67
28	1	3,33
32	1	3,33
Σ	30	100

Síntese dos dados

Distribuição de Frequência com Intervalo de Classe

Os dados a seguir referem-se ao tempo gasto com auditoria , medido em dias, em uma amostra de 30 empresas.

23	21	20	22	14	14	15	27	21	23	19	18	22	32	21
18	22	23	28	12	23	26	27	19	25	17	20	17	23	18

$$\text{Número de classes (K)} = \sqrt{n}$$

$$\text{Amplitude Total (AT)} = (\text{> Valor}) - (\text{< Valor})$$

$$\text{Amplitude das Classes (h)} = \frac{(AT)}{(K)}$$

Síntese dos dados

Distribuição de Frequência com Intervalo de Classe

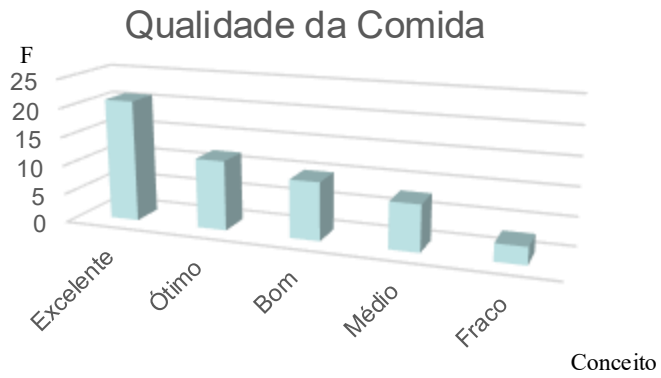
Os dados a seguir referem-se ao tempo gasto com auditoria , medido em dias, em uma amostra de 30 empresas.

23	21	20	22	14	14	15	27	21	23	19	18	22	32	21
18	22	23	28	12	23	26	27	19	25	17	20	17	23	18

Levantamento de auditoria		
Tempo (dias)	F	F%
12/----- 16	4	13,33
16/----- 20	7	23,33
20/----- 24	13	43,33
24/----- 28	4	13,33
28/-----/32	2	6,67
Σ	30	100,00

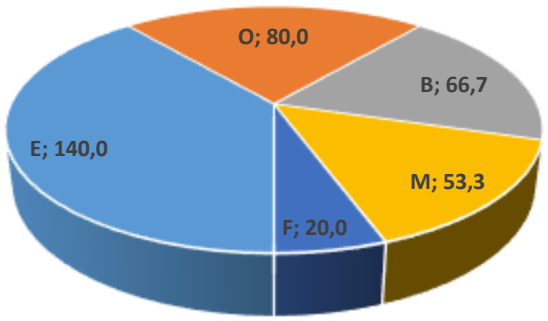
Síntese dos dados

Representação Gráfica



Qualidade da Comida

Conceito	F	F%	Graus
E	21	38,9	140,0
O	12	22,2	80,0
B	10	18,5	66,7
M	8	14,8	53,3
F	3	5,56	20,0
Σ	54	100	360,0



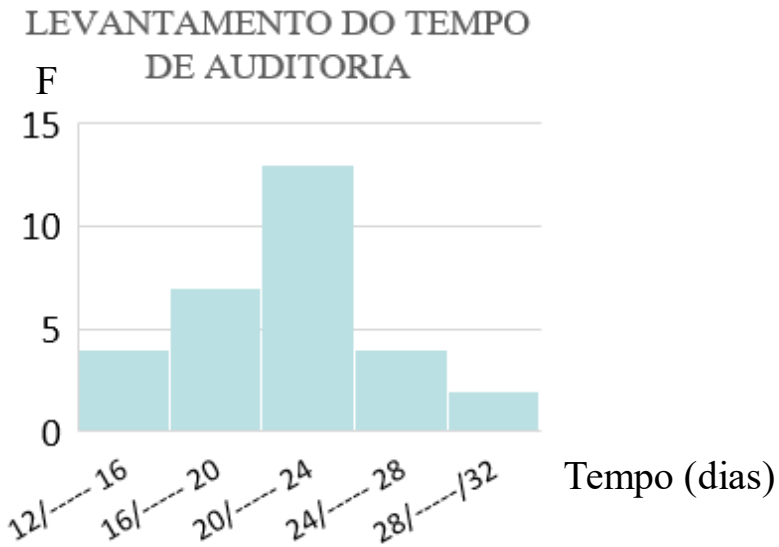
38,9/100 * 360 = 140 graus

Síntese dos dados

Representação Gráfica

HISTOGRAMA

Levantamento do tempo de auditoria		
Tempo (dias)	F	F%
12/----- 16	4	13,33
16/----- 20	7	23,33
20/----- 24	13	43,33
24/----- 28	4	13,33
28/-----/32	2	6,67
Σ	30	100,00

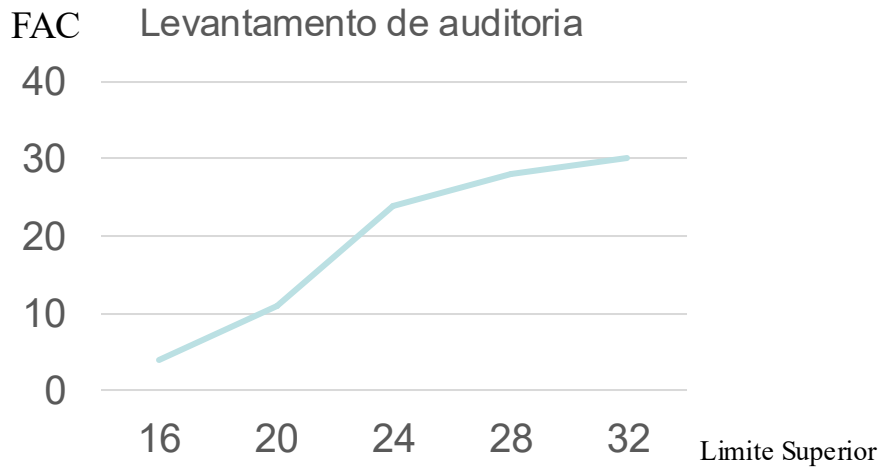


Síntese dos dados

Representação Gráfica

FREQUÊNCIA ACUMULADA

Levantamento de auditoria		
Tempo (dias)	F	FAC
12/----- 16	4	4
16/----- 20	7	11
20/----- 24	13	24
24/----- 28	4	28
28/-----/32	2	30



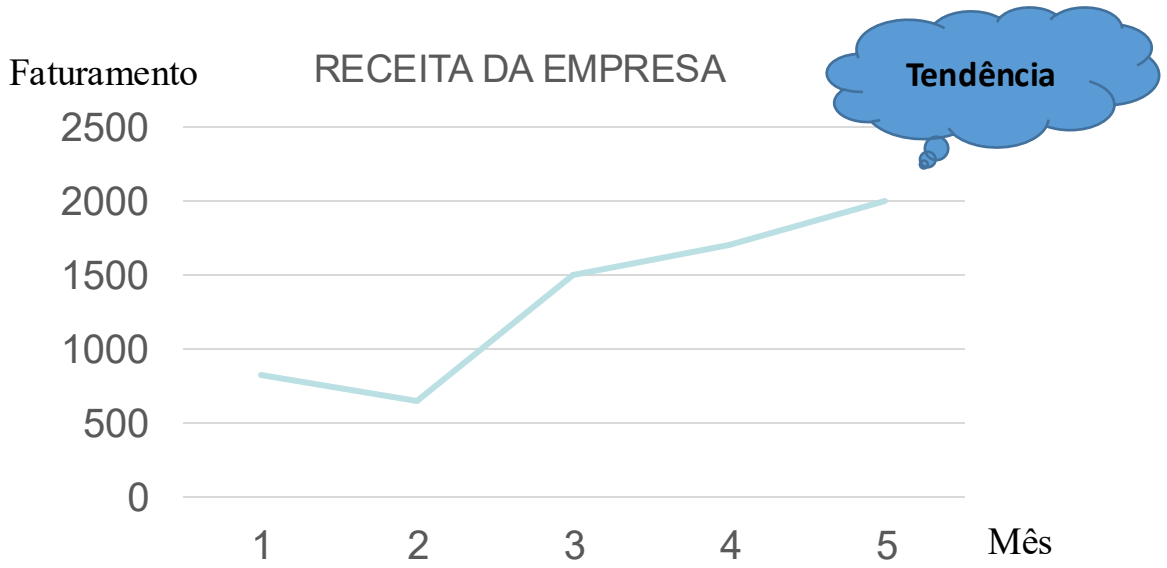
Síntese dos dados

Representação Gráfica

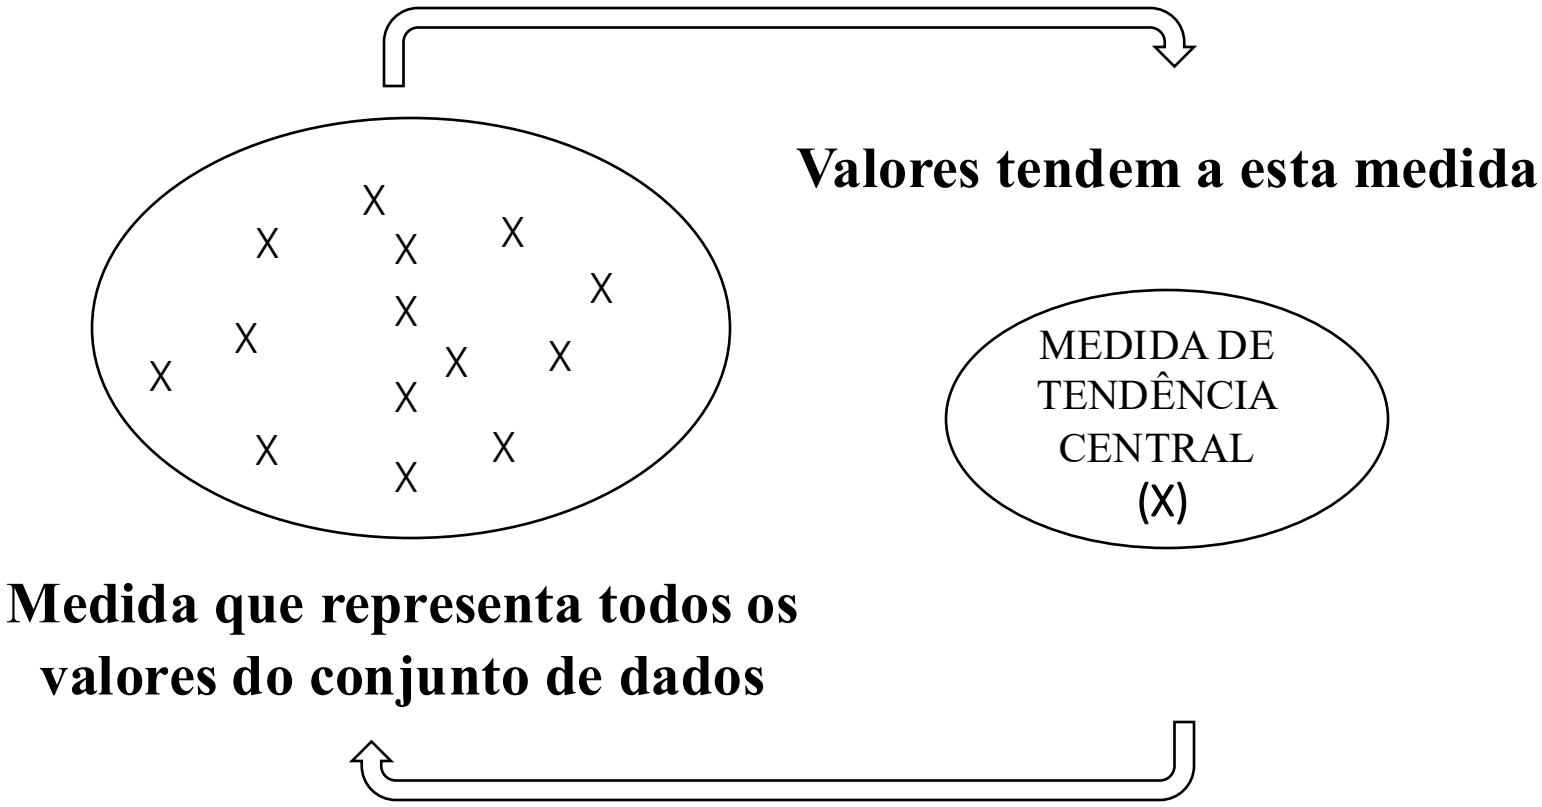
GRÁFICO DE LINHA

Série Temporal

RECEITA DA EMPRESA	
Mês	Faturamento (mil R$)
1	820
2	650
3	1500
4	1700
5	2000



MEDIDAS DE TENDÊNCIA CENTRAL



MEDIDAS DESCRITIVAS

Média para dados não agrupados

$$\mu \; ou \; \bar{x} = \frac{\sum(\mathrm{X})}{\mathrm{n}}$$

A fim de conhecer o nº de irmãos dos alunos de uma determinada turma foi feita uma **amostragem** com 12 alunos obtendo as seguintes respostas: Calcule a média.

0 3 4 2 2 2 1 2 1 5 0 4

$\bar{x} = \frac{26}{12}$ = 2,17 Aproximadamente **2** irmãos por aluno

MEDIDAS DESCRITIVAS

Média para dados agrupados

$$\mu \; ou \; \bar{x} = \frac{\sum(X * \mathrm{F})}{\sum(\mathrm{F})}$$

Primeira avaliação		
Notas (Pontos)	F	(X*F)
0,0	7	0
1,0	10	10
1,5	3	4,5
2,5	8	20
4,0	2	8
6,0	15	90
7,5	6	45
9,5	2	19
∑	53	196,5

Levantamento de auditoria			
Tempo (dias)	F	Pm(X)	(X*F)
12/----- 16	4	14	56
16/----- 20	7	18	126
20/----- 24	13	22	286
24/----- 28	4	26	104
28/-----/32	2	30	60
Σ	30		632

$$\mu = \frac{196,5}{53} = 3,7 \text{ pontos}$$

$$\bar{x} = \frac{632}{30} = 21 \text{ dias}$$

MEDIDAS DESCRITIVAS

Moda - Mo

Valor da série ou distribuição que está em evidência, que aparece mais vezes, que possui maior frequência.

Dados não agrupados

7 8 9 10 10 10 11 12 13 14 15 Mo = 10 unidades

3 5 10 12 13 Mo = Amodal

2 3 4 4 4 5 6 7 7 7 8 9 Mo = Bimodal (4 e 7) unidades

MEDIDAS DESCRITIVAS

Moda – Mo

Dados agrupados

Dados agrupados sem intervalo

X	F
0	2
1	6
2	10
3	12
4	4

Mo = 3 unidades

MEDIDAS DESCRITIVAS

Moda – Mo

Dados agrupados com intervalo

X	F
0,0/----- 1,0	3
1,0/----- 2,0	10
2,0/----- 3,0	17
3,0/----- 4,0	8
4,0/-----/5,0	5

$$Mo = L + \left(\frac{D1}{D1+D2}\right) . h$$

L = Limite inferior da classe modal
D1 = Frequência da classe modal – Frequência anterior
D2 = Frequência da classe modal – Frequência posterior
h = Amplitude da classe modal

$$Mo = 2,0 + \left(\frac{7}{7+9}\right) . 1,0 = 2,4 \text{ unidades}$$

MEDIDAS DESCRITIVAS

Mediana - Md

Elemento que ocupa a posição central em uma série ORDENADA ou distribuição de dados.

Dados não agrupados e n = impar

10 8 5 14 7

Rol = {5 – 7 - 8 - 10 – 14}

(n+1)/2 = Posição do elemento mediano

Portanto: (5+1)/2 = 3º Posição da série

Assim: Md = 8 unidades

MEDIDAS DESCRITIVAS

Mediana - Md

Dados não agrupados e n = Par

10 5 8 14 7 15

Rol = {5 – 7 - 8 - 10 – 14 - 15}

1º elemento central (n/2)

2º elemento central (n/2) +1

Portanto: Md = (1º elemento central + 2º elemento central) / 2

Assim: Md = (8 + 10) / 2 = 9 unidades

MEDIDAS DESCRITIVAS

Mediana – Md

Dados agrupados e n = Impar

X	F	FAC
1	1	1
2	3	4
3	5	9
4	2	11

Posição do elemento mediano: (n+1)/2

Portanto: (11+1)/2 = 6º posição

Assim: Md = 3 unidades

MEDIDAS DESCRITIVAS

Mediana - Md

Dados agrupados e n = Par

X	F	FAC
82	5	5
85	10	15
87	15	30
89	8	38
90	4	42

Sendo a Md = (1º elemento central + 2º elemento central) / 2

1º elemento central (n/2) = 42/2 = 21º posição

2º elemento central (n/2)+1 =(42/2) +1 = 22º posição

Assim: Md = (87+87)/2 = 87 unidades

MEDIDAS DESCRITIVAS

Mediana - Md

Dados agrupados com intervalo de classe

X	F	FAC
35/----- 45	5	5
45/----- 55	12	17
55/----- 65	18	35
65/----- 75	14	49
75/-----/85	6	55
85/-----/95	3	58

$$Md = 55 + \left\{\frac{(29-17)*10}{18}\right\} = 61{,}7 \text{ unidades}$$

$$Md = L + \left\{\frac{\left(\frac{\sum F}{2} - FAC\ (Ant)\right) * h}{F}\right\}$$

L = Limite inferior da classe mediana

$(\frac{\sum F}{2})$ = Posição do elemento mediano

$FAC\ (Ant)$ = Frequência acumulada anterior à frequência acumulada da classe mediana

h = Amplitude da classe mediana

F = Frequência da classe mediana

MEDIDAS DESCRITIVAS

Aplicação das Medidas de Tendência Central

Normalmente quando precisamos de uma medida de tendência central utilizamos a média pois ela leva em conta todos os valores do conjunto de dados, porém existem situações em que a média não é aplicável sendo necessários utilizar as outras medidas de tendência central.

A Mediana é indicada quando no conjunto de dados existem valores **extremos** que mascaram a média.

{ 28 – 26 – 24 - 29 – 304 - 21 - 22 }

μ = 454 / 7 aproximadamente 65

Rol = { 21 – 22 – 24 - 26 – 28 - 29 - 304 }

$\boldsymbol{Md}$ **= 26**

MEDIDAS DESCRITIVAS

Aplicação das Medidas de Tendência Central

A moda é utilizada quando a distribuição refere-se a dados qualitativos.

Qualidade da Comida		
Conceito	F	F%
E	21	38,89
O	12	22,22
B	10	18,52
M	8	14,81
F	3	5,56

Mo = Excelente

MEDIDAS DESCRITIVAS

Aplicação das Medidas de Tendência Central

A moda também deve utilizada quando a distribuição refere-se a dados quantitativos e existir determinado valor ou intervalo de valores que se destaca em relação aos outros, fazendo com que a média não seja representativa.

Nº de irmãos	F
0	143
1	298
2	132
3	83
4	57
5	24

μ = 1159 / 737 = 1,57 Aproximadamente 2 irmãos

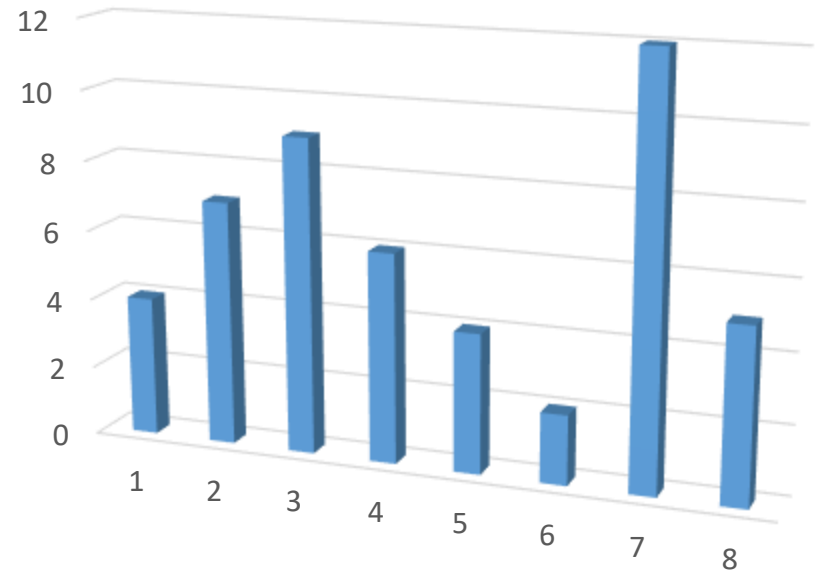
Mo = 1 irmão

MEDIDAS DESCRITIVAS

Aplicação das Medidas de Tendência Central

A moda também é indicada quando a distribuição dos dados conter 2 ou mais picos separados por vales.

X	F
1	4
2	7
3	9
4	6
5	4
6	2
7	12
8	5

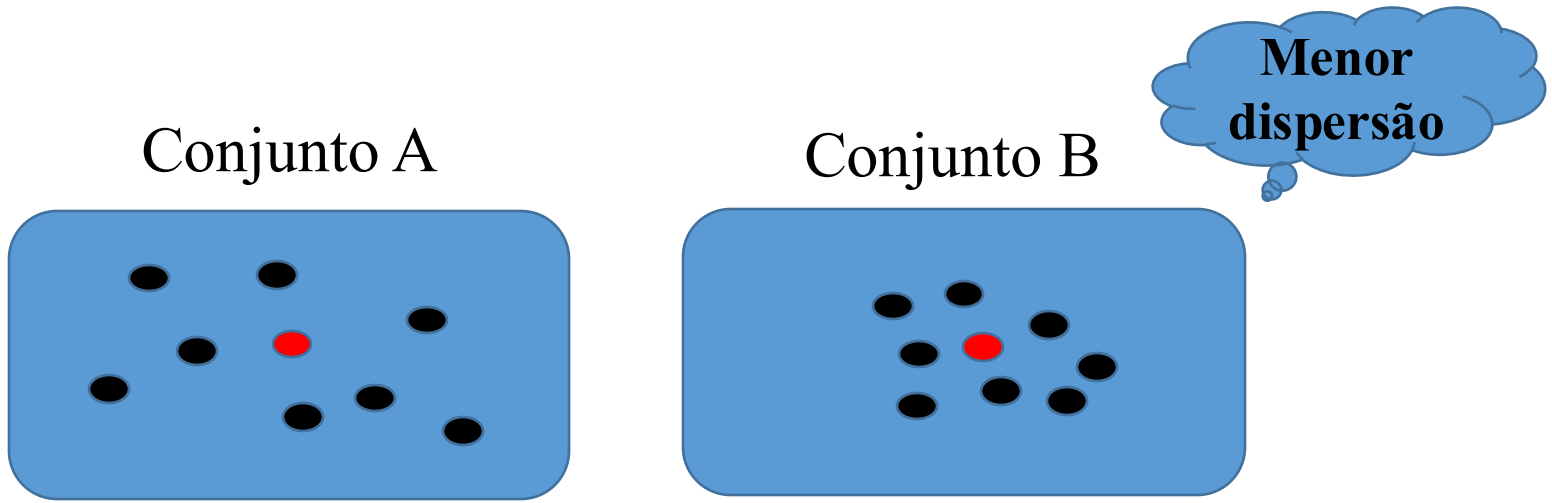


Distribuição Bi Modal (3 e 7)

MEDIDAS DESCRITIVAS

Medidas de dispersão ou variabilidade

É aquela que mede a distância entre os valores do conjunto de dados e sua média; Através dela podemos avaliar a homogeneidade dos valores da variável, como também a representatividade da medida de tendência central.

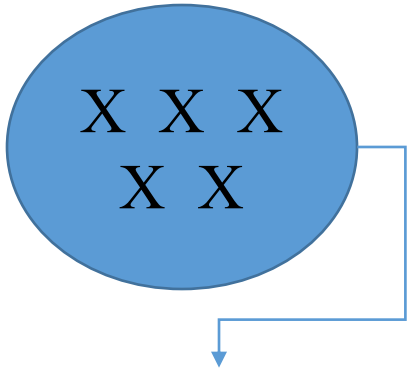


MEDIDAS DESCRITIVAS

Medidas de dispersão ou variabilidade

Um comprador está desenvolvendo novos fornecedores para certa matéria prima. Para tanto enviou 5 pedidos para dois fornecedores selecionados, a fim de avaliar o tempo de entrega em dias.

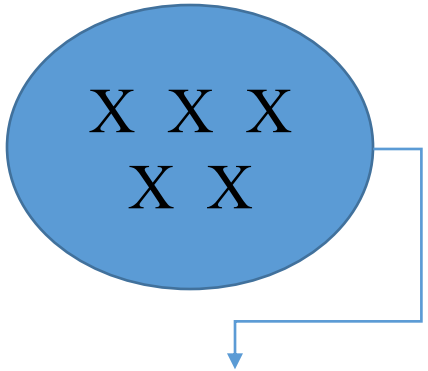
Fornecedor A



Média = 10 dias

{8 – 9 - 10 – 11 - 12}

Fornecedor B



Média = 10 dias

{4 – 6 - 9 – 13 - 18}

MEDIDAS DESCRITIVAS

Medidas de dispersão ou variabilidade

Variância: É a soma das diferenças entre o valor da variável e a média do conjunto de dados, sendo a soma elevada ao quadrado

Desvio Padrão: É a raiz da variância.

Desvio Padrão Populacional: $\sigma = \sqrt{\frac{\sum[F*(x-\mu)^2]}{n}}$

Desvio Padrão Amostral $S = \sqrt{\frac{\sum[F*(x-\bar{x})^2]}{n-1}}$

MEDIDAS DESCRITIVAS

Medidas de dispersão ou variabilidade

σ do fornecedor A

X	F	X*F	F∗(x-μ)²
8	1	8	4
9	1	9	1
10	1	10	0
11	1	11	1
12	1	12	4
∑	5	50	10

σ do fornecedor B

X	F	X*F	F∗(x-μ)²
4	1	4	36
6	1	6	16
9	1	9	1
13	1	13	9
18	1	18	64
∑	5	50	126

$\mu(A) = \frac{50}{5} = 10$

$$\sigma = \sqrt{\frac{\sum[F * (x - \mu)^2]}{n}}$$

$\mu(B) = \frac{50}{5} = 10$

$\sigma(A) = \sqrt{\frac{10}{5}} = 1{,}4$ dias

$\sigma(B) = \sqrt{\frac{126}{5}} = 5$ dias

MEDIDAS DESCRITIVAS

Medidas de dispersão ou variabilidade

Coeficiente de variação

Quando estamos interessados em uma medida descritiva que indica o tamanho do desvio padrão em relação a média, a fim de saber entre conjuntos de dados qual possui menor dispersão ou média mais representativa, utilizamos o coeficiente de variação, dados por:

$$\text{CV} = \left(\frac{desvio\ padrão}{média}\right)$$

Quanto menor o CV mais representativa é a média e consequentemente menor é a dispersão dos dados

Média mais representativa e menor dispersão

Conjunto A	*Conjunto B*
$\mu = 37{,}7$ unidades	$\mu = 30{,}1$ unidades
$\sigma = 11{,}2\ unidades$	$\sigma = 10{,}5\ unidades$
CV = 29,7%	CV = 35,0%

MEDIDAS DESCRITIVAS

Medidas de dispersão ou variabilidade

Calcule o desvio padrão e o coeficiente de variação do conjunto de dados

Notas (Pontos)	F	P.m. (x)	X*F	$F * (x - \mu)^2$
4,0|---- 5,0	2	4,5	9,0	9,42
5,0|---- 6,0	5	5,5	27,5	6,84
6,0|---- 7,0	13	6,5	84,5	0,37
7,0|---- 8,0	6	7,5	45,0	4,13
8,0|---- 9,0	4	8,5	34,0	13,39
∑	**30**	**-**	**200**	**34,15**

$$\mu = \frac{\sum(X * F)}{\sum(F)} \qquad \sigma = \sqrt{\frac{\sum[F * (x - \mu)^2]}{n}} \qquad CV = \left(\frac{desvio\ padrão}{média}\right)$$

$$\mu = \frac{200}{30} = 6{,}67 \text{ pontos} \qquad \sigma = \sqrt{\frac{34{,}15}{30}} = 1{,}07 \text{ pontos} \qquad CV = \frac{1{,}07}{6{,}67} = 16{,}04\%$$

DISTRIBUIÇÃO DE PROBABILIDADE

PARA VARIÁVEL CONTÍNUA
CURVA NORMAL

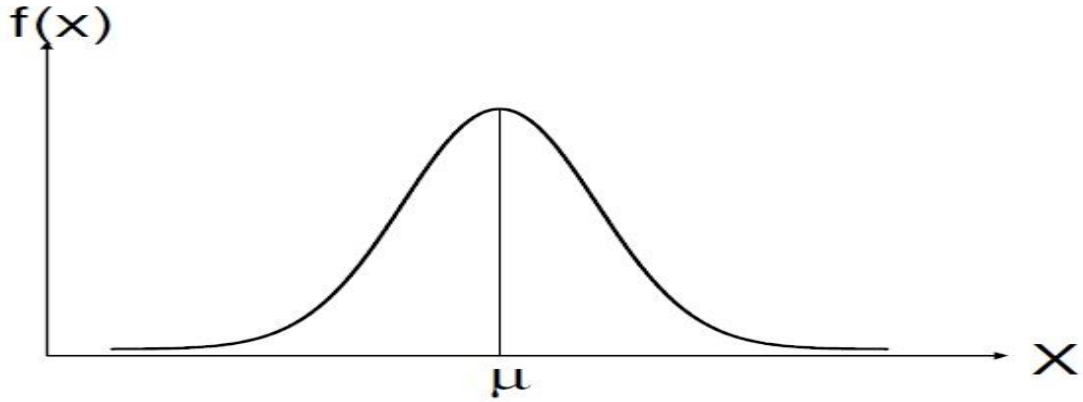

Dr. C.F. Gauss

Através de processos de observação o matemático, astrônomo e físico Carl Friedrich Gauss constatou que coletado um conjunto de dados de variáveis contínuas sua distribuição formava naturalmente uma curva característica, a partir daí elaborou estudos específicos sobre este fenômeno, denominado:

Curva Normal ou Curva de Gauss.

Propriedades da curva Normal ou de Gauss

1ª - A representação gráfica da distribuição normal é uma curva em forma de sino, simétrica em torno da média.



2ª - A variável aleatória X pode assumir qualquer valor real.

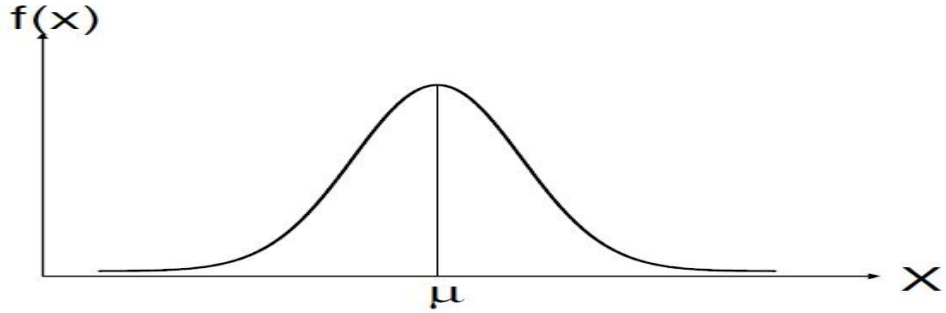
3ª - A área total limitada pela curva e pelo eixo das abscissas é igual a 1.

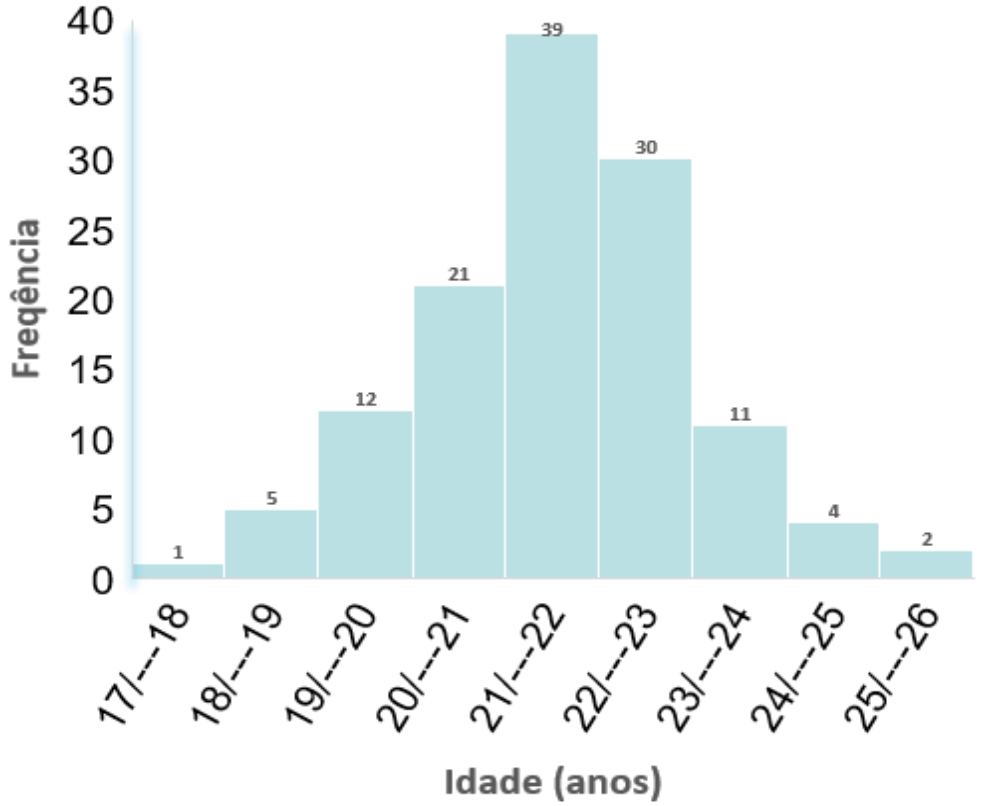
4ª - A curva normal é assintótica em relação ao eixo das abscissas, isto é, aproxima-se indefinidamente do eixo das abscissas sem, contudo, alcançá-lo.

5ª - Como a curva é simétrica em torno da média, a probabilidade de ocorrer valor maior que a média é igual à probabilidade de ocorrer valor menor do que a média.

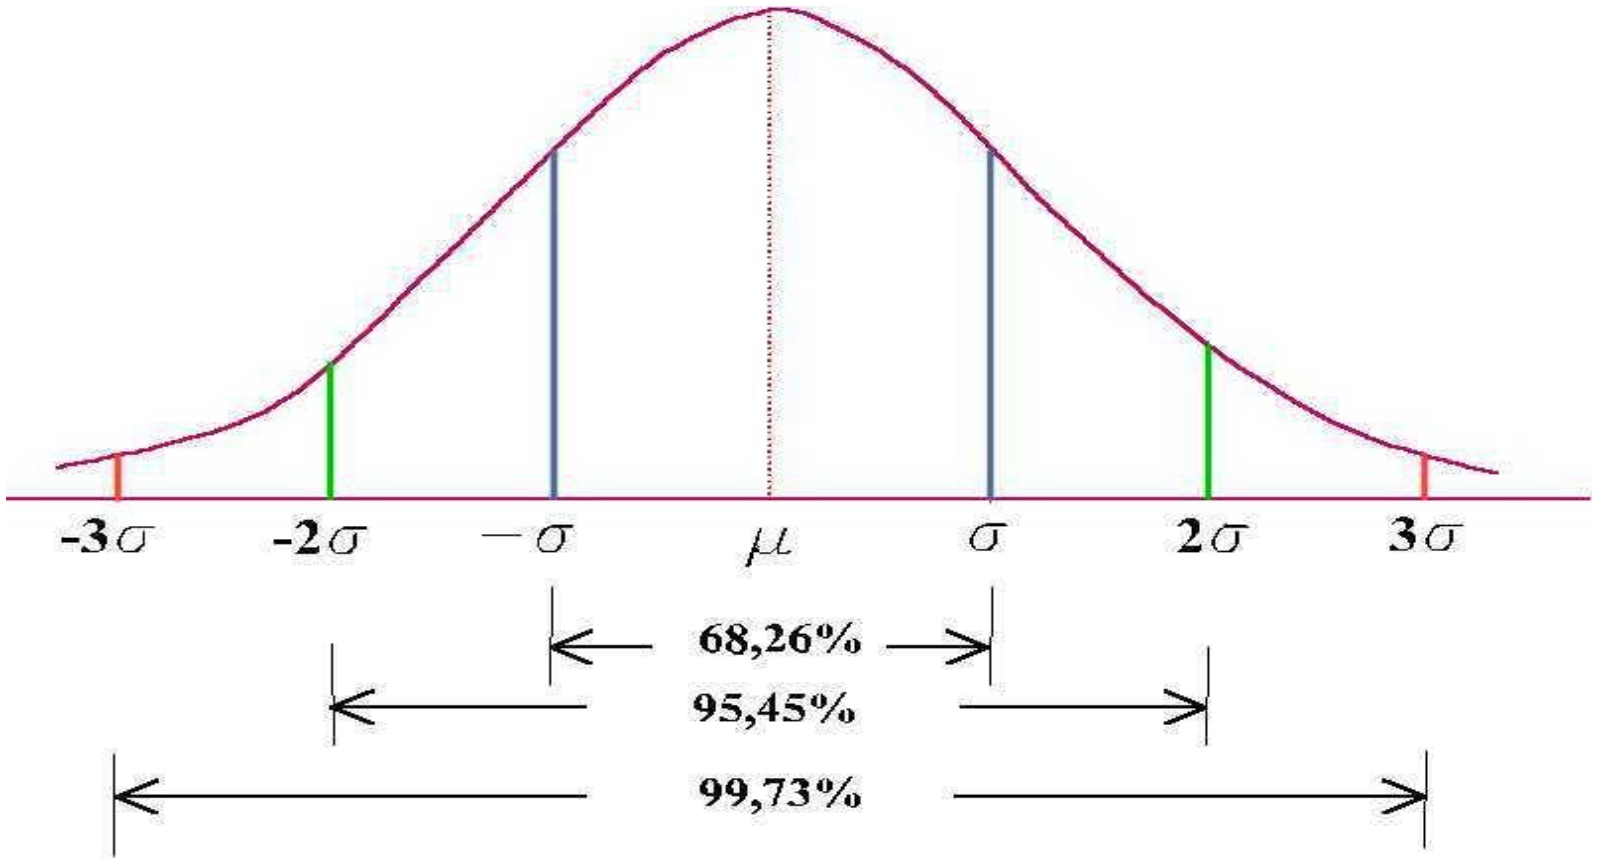
Histograma x Distribuição Normal

Idade (anos)	F
17/-----18	1
18/-----19	5
19/-----20	12
20/-----21	21
21/-----22	39
22/-----23	30
23/-----24	11
24/-----25	4
25/-----26	2
∑	125





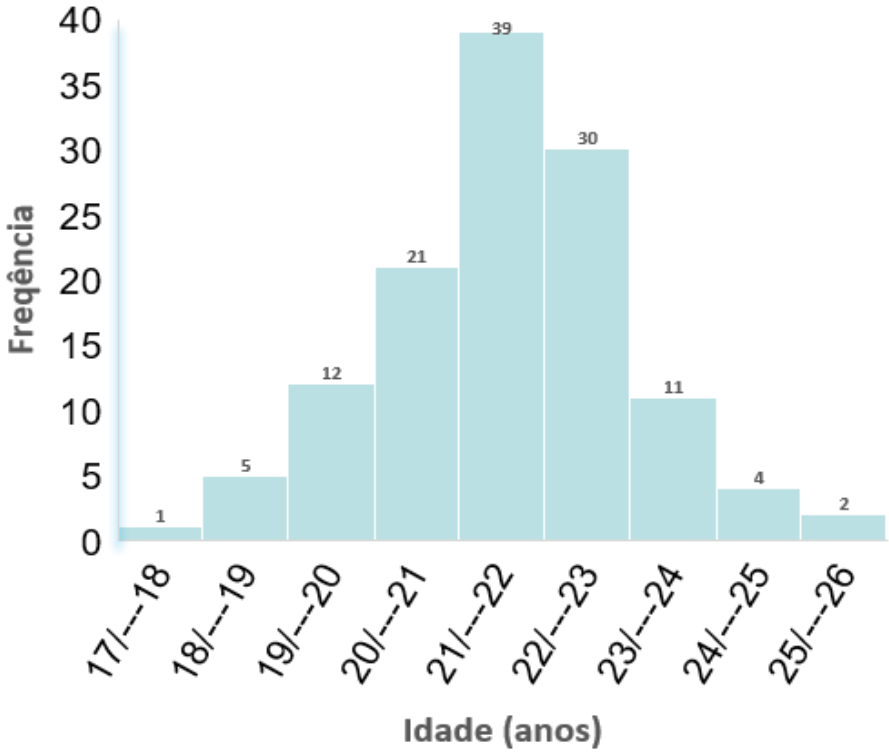
Área sob a distribuição Normal

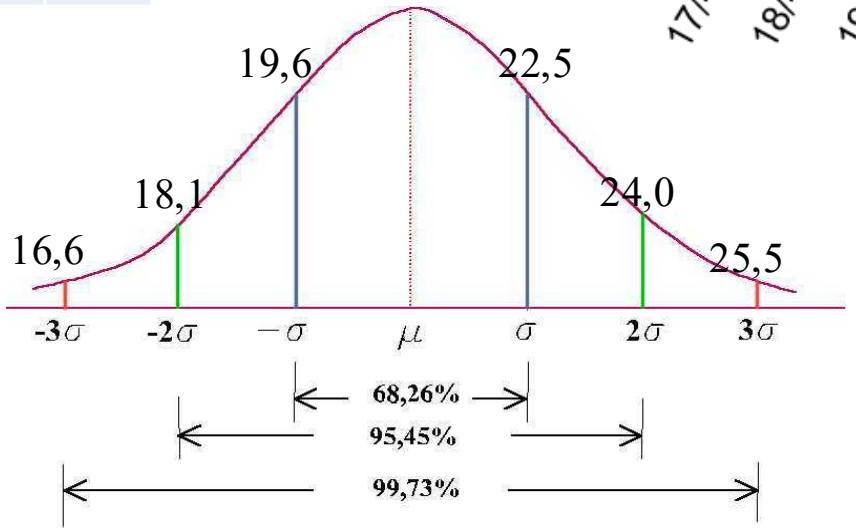


Histograma X Área sob a distribuição normal

Idade (anos)	F
17/-----18	1
18/-----19	5
19/-----20	12
20/-----21	21
21/-----22	39
22/-----23	30
23/-----24	11
24/-----25	4
25/-----26	2
∑	125

Média	21,1
Desvio	1,47





Distribuição Normal Padronizada

- A distribuição normal padronizada tem média e desvio padrão iguais a:

$$\mu = 0 \qquad \sigma = 1$$

- **A distribuição normal padronizada facilita os cálculos de probabilidade, evitando o uso da fórmula e projetando qualquer análise mediante utilização de ESCORES (Z)**

$$z = \frac{x - \mu}{\sigma}$$

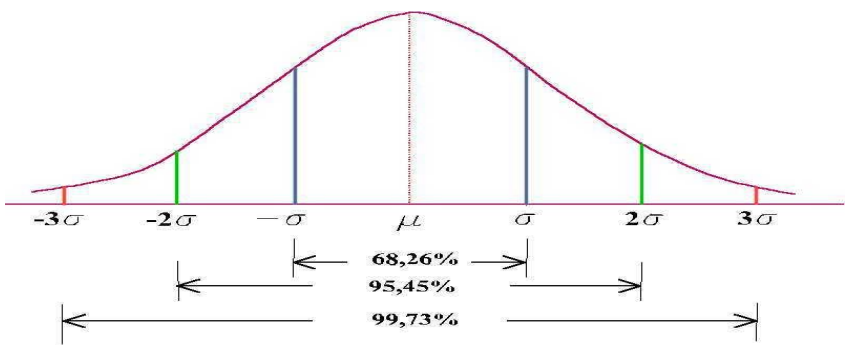


Tabela A6.2 Distribuição normal — valores de $P(0 \leqslant Z \leqslant z_0)$

z_0	0	1	2	3	4	5	6	7	8	9
0,0	0,0000	0,0040	0,0080	0,0120	0,0160	0,0199	0,0239	0,0279	0,0319	0,0359
0,1	0,0398	0,0438	0,0478	0,0517	0,0557	0,0596	0,0636	0,0675	0,0714	0,0753
0,2	0,0793	0,0832	0,0871	0,0910	0,0948	0,0987	0,1026	0,1064	0,1103	0,1141
0,3	0,1179	0,1217	0,1255	0,1293	0,1331	0,1368	0,1406	0,1443	0,1480	0,1517
0,4	0,1554	0,1591	0,1628	0,1664	0,1700	0,1736	0,1772	0,1808	0,1844	0,1879
0,5	0,1915	0,1950	0,1985	0,2019	0,2054	0,2088	0,2123	0,2157	0,2190	0,2224
0,6	0,2257	0,2291	0,2324	0,2357	0,2389	0,2422	0,2454	0,2486	0,2517	0,2549
0,7	0,2580	0,2611	0,2642	0,2673	0,2703	0,2734	0,2764	0,2794	0,2823	0,2852
0,8	0,2881	0,2910	0,2939	0,2967	0,2995	0,3023	0,3051	0,3078	0,3106	0,3133
0,9	0,3159	0,3186	0,3212	0,3238	0,3264	0,3289	0,3315	0,3340	0,3365	0,3389
1,0	0,3413	0,3438	0,3461	0,3485	0,3508	0,3531	0,3554	0,3577	0,3599	0,3621
1,1	0,3643	0,3665	0,3686	0,3708	0,3729	0,3749	0,3770	0,3790	0,3810	0,3830
1,2	0,3849	0,3869	0,3888	0,3907	0,3925	0,3944	0,3962	0,3980	0,3997	0,4015
1,3	0,4032	0,4049	0,4066	0,4082	0,4099	0,4115	0,4131	0,4147	0,4162	0,4177
1,4	0,4192	0,4207	0,4222	0,4236	0,4251	0,4265	0,4279	0,4292	0,4306	0,4319
1,5	0,4332	0,4345	0,4357	0,4370	0,4382	0,4394	0,4406	0,4418	0,4429	0,4441
1,6	0,4452	0,4463	0,4474	0,4484	0,4495	0,4505	0,4515	0,4525	0,4535	0,4545
1,7	0,4554	0,4564	0,4573	0,4582	0,4591	0,4599	0,4608	0,4616	0,4625	0,4633
1,8	0,4641	0,4649	0,4656	0,4664	0,4671	0,4678	0,4686	0,4693	0,4699	0,4706
1,9	0,4713	0,4719	0,4726	0,4732	0,4738	0,4744	0,4750	0,4756	0,4761	0,4767
2,0	0,4772	0,4778	0,4783	0,4788	0,4793	0,4798	0,4803	0,4808	0,4812	0,4817
2,1	0,4821	0,4826	0,4830	0,4834	0,4838	0,4842	0,4846	0,4850	0,4854	0,4857
2,2	0,4861	0,4864	0,4868	0,4871	0,4875	0,4878	0,4881	0,4884	0,4887	0,4890
2,3	0,4893	0,4896	0,4898	0,4901	0,4904	0,4906	0,4909	0,4911	0,4913	0,4916
2,4	0,4918	0,4920	0,4922	0,4925	0,4927	0,4929	0,4931	0,4932	0,4934	0,4936
2,5	0,4938	0,4940	0,4941	0,4943	0,4945	0,4946	0,4948	0,4949	0,4951	0,4952
2,6	0,4953	0,4955	0,4956	0,4957	0,4959	0,4960	0,4961	0,4962	0,4963	0,4964
2,7	0,4965	0,4966	0,4967	0,4968	0,4969	0,4970	0,4971	0,4972	0,4973	0,4974
2,8	0,4974	0,4975	0,4967	0,4977	0,4977	0,4978	0,4979	0,4979	0,4980	0,4981
2,9	0,4981	0,4982	0,4982	0,4983	0,4984	0,4984	0,4985	0,4985	0,4986	0,4986
3,0	0,4987	0,4987	0,4987	0,4988	0,4988	0,4989	0,4989	0,4989	0,4990	0,4990
3,1	0,4990	0,4991	0,4991	0,4991	0,4992	0,4992	0,4992	0,4992	0,4993	0,4993
3,2	0,4993	0,4993	0,4994	0,4994	0,4994	0,4994	0,4994	0,4995	0,4995	0,4995
3,3	0,4995	0,4995	0,4995	0,4996	0,4996	0,4996	0,4996	0,4996	0,4996	0,4997
3,4	0,4997	0,4997	0,4997	0,4997	0,4997	0,4997	0,4997	0,4997	0,4997	0,4998
3,5	0,4998	0,4998	0,4998	0,4998	0,4998	0,4998	0,4998	0,4998	0,4998	0,4998
3,6	0,4998	0,4998	0,4999	0,4999	0,4999	0,4999	0,4999	0,4999	0,4999	0,4999
3,7	0,4999	0,4999	0,4999	0,4999	0,4999	0,4999	0,4999	0,4999	0,4999	0,4999
3,8	0,4999	0,4999	0,4999	0,4999	0,4999	0,4999	0,4999	0,4999	0,4999	0,4999
3,9	0,5000	0,5000	0,5000	0,5000	0,5000	0,5000	0,5000	0,5000	0,5000	0,5000

APLICAÇÃO DA CURVA NORMAL REDUZIDA

$$z = \frac{x - \mu}{\sigma}$$

As alturas dos alunos de uma determinada escola são normalmente distribuídas com média = 1,60 m e desvio padrão de 0,3 m. Escolhendo um aluno aleatoriamente, qual a chance dele medir:

A) Entre 1,5 m e 1,8 m

B) Mais de 1,75 m

C) Menos de 1,48 m

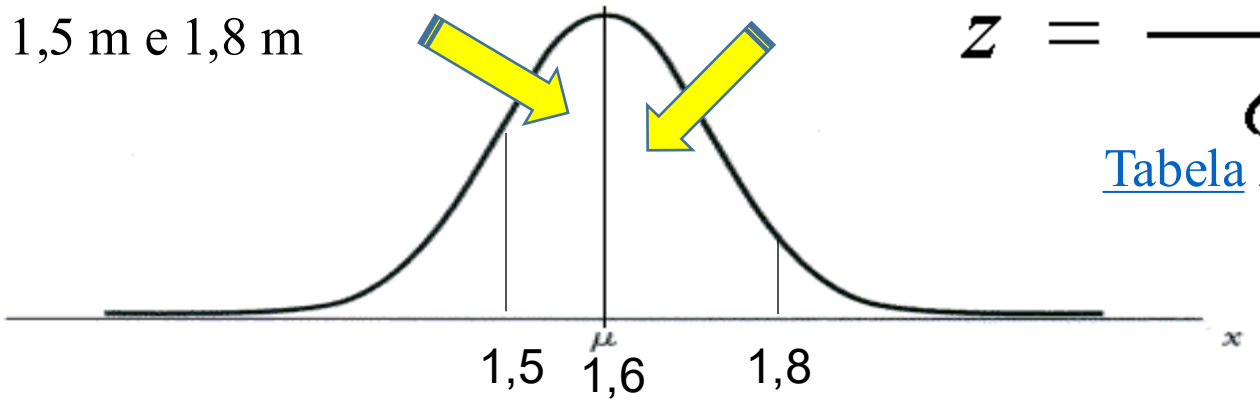
D) Mais de 1,5 m

E) Entre 1,45 m e 1,55 m

APLICAÇÃO DA CURVA NORMAL REDUZIDA

As alturas dos alunos de uma determinada escola são normalmente distribuídas com média = 1,60 m e desvio padrão de 0,3 m. Escolhendo um aluno aleatoriamente, qual a chance dele medir:

A) Entre 1,5 m e 1,8 m



$$z = \frac{x - \mu}{\sigma}$$

Tabela Z

$$Z1 = \frac{1,5 - 1,6}{0,3} = -0,33\ (0,1293) \qquad Z2 = \frac{1,8 - 1,6}{0,3} = 0,67\ (0,2486)$$

P(E) = 0,1293 + 0,2486 = 0,3779 ou 37,79%

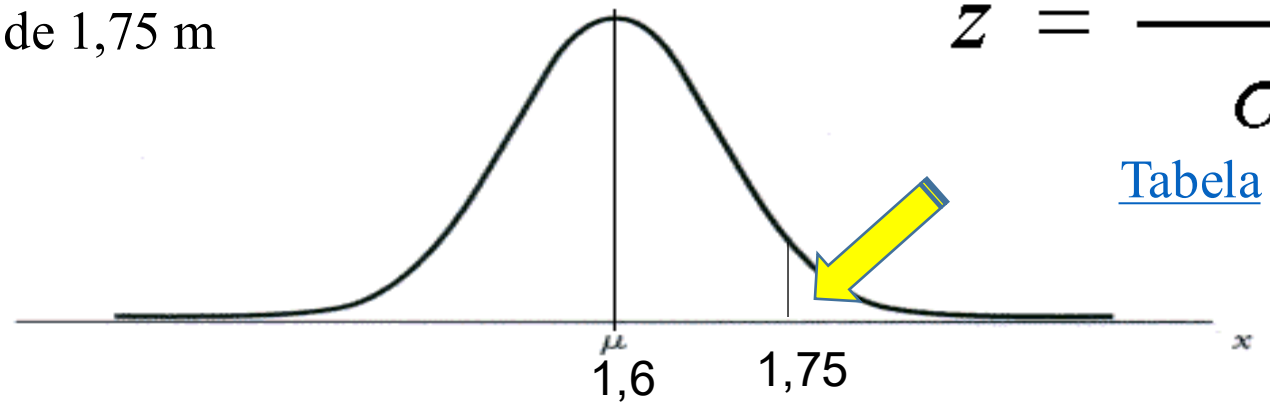
APLICAÇÃO DA CURVA NORMAL REDUZIDA

As alturas dos alunos de uma determinada escola são normalmente distribuídas com média = 1,60 m e desvio padrão de 0,3 m. Escolhendo um aluno aleatoriamente, qual a chance dele medir:

B) Mais de 1,75 m

$$z = \frac{x - \mu}{\sigma}$$

Tabela Z



$$Z1 = \frac{1{,}75 - 1{,}6}{0{,}3} = -0{,}50\ (0{,}1915)$$

P(E) = 0,5 – 0,1915 = 0,3085 ou 30,85%

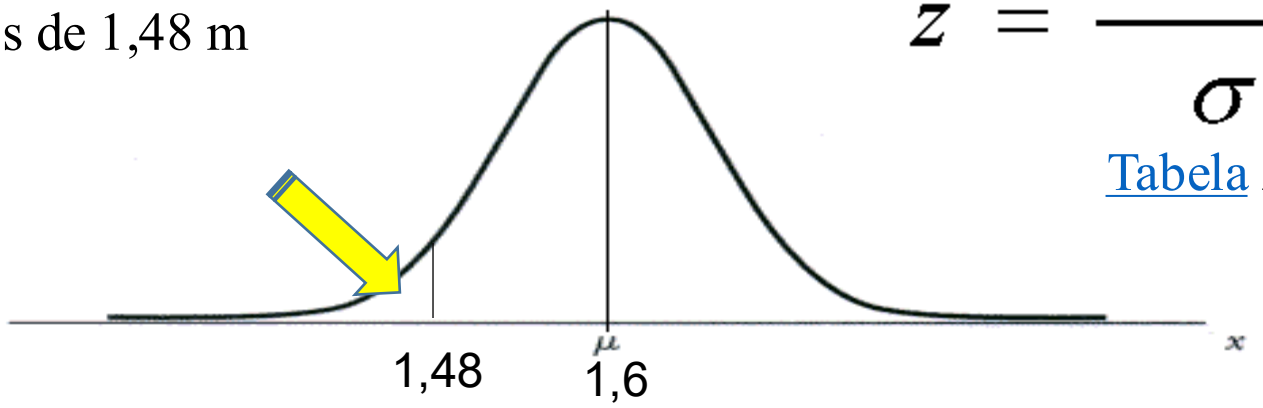
APLICAÇÃO DA CURVA NORMAL REDUZIDA

As alturas dos alunos de uma determinada escola são normalmente distribuídas com média = 1,60 m e desvio padrão de 0,3 m. Escolhendo um aluno aleatoriamente, qual a chance dele medir:

C) Menos de 1,48 m

$$z = \frac{x - \mu}{\sigma}$$

Tabela Z



$$Z1 = \frac{1,48 - 1,6}{0,3} = -0,40\ (0,1554)$$

P(E) = 0,5 – 0,1554 = 0,3446 ou 34,46%

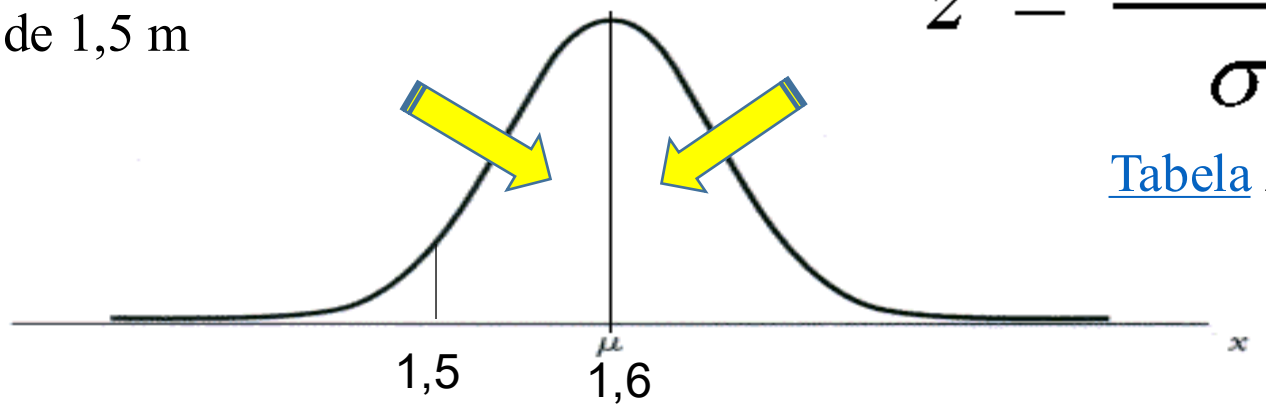
APLICAÇÃO DA CURVA NORMAL REDUZIDA

As alturas dos alunos de uma determinada escola são normalmente distribuídas com média = 1,60 m e desvio padrão de 0,3 m. Escolhendo um aluno aleatoriamente, qual a chance dele medir:

$$z = \frac{x - \mu}{\sigma}$$

D) Mais de 1,5 m

Tabela Z



$$Z1 = \frac{1,5 - 1,6}{0,3} = -0,33\ (0,1293)$$

P(E) = 0,1293 + 0,5 = 0,6293 ou 62,93%

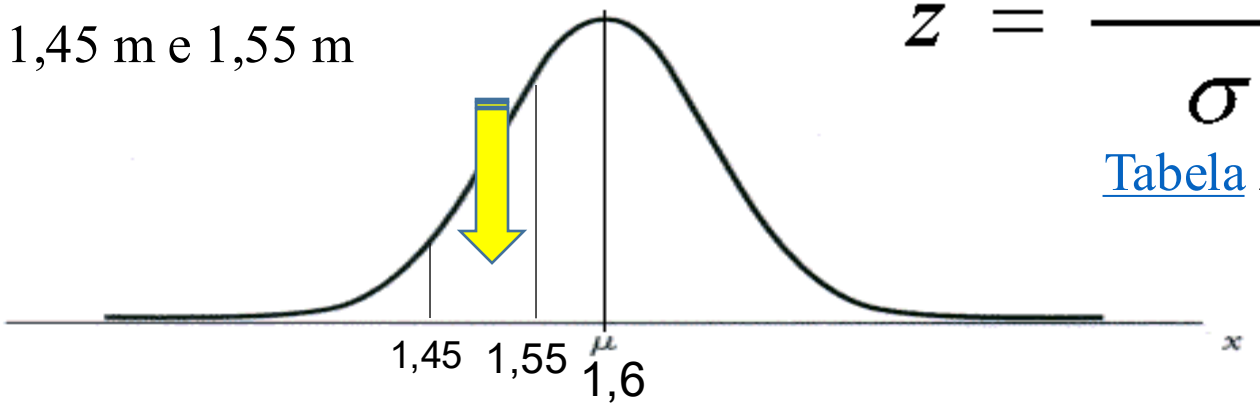
APLICAÇÃO DA CURVA NORMAL REDUZIDA

As alturas dos alunos de uma determinada escola são normalmente distribuídas com média = 1,60 m e desvio padrão de 0,3 m. Escolhendo um aluno aleatoriamente, qual a chance dele medir:

E) Entre 1,45 m e 1,55 m

$$z = \frac{x - \mu}{\sigma}$$

Tabela Z



$$Z1 = \frac{1{,}45 - 1{,}6}{0{,}3} = -0{,}50\ (0{,}1915) \qquad Z2 = \frac{1{,}55 - 1{,}6}{0{,}3} = -0{,}17\ (0{,}0675)$$

P(E) = 0,1915 – 0,0675 = 0,124 ou 12,4%

BOXPLOT

Gráfico utilizado para avaliar a simetria, dispersão e a existência de pontos extremos em um conjunto de valores, a fim comparar conjuntos de dados, e é elaborado com as seguintes medidas:

Mediana

Quartil 1

Quartil 3

AIQ (Amplitude interquartil) = Q3 – Q1

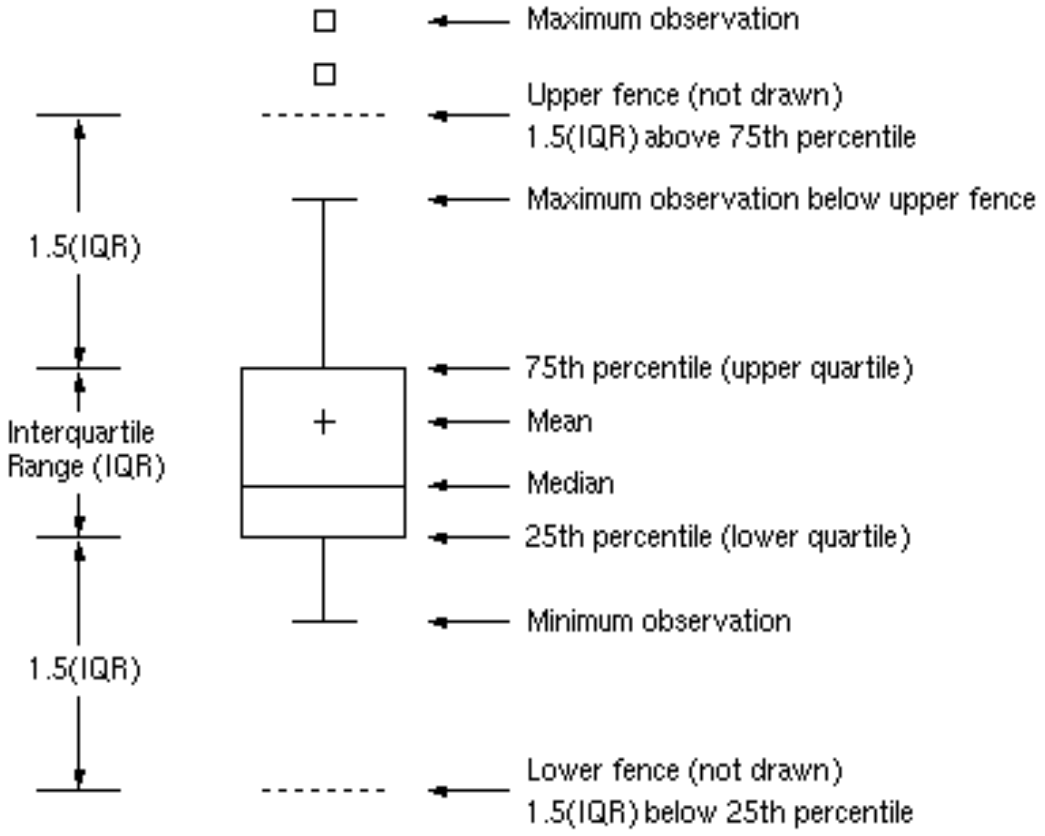
LS (limite superior = Q3 + (1,5 * AIQ)

LI (limite inferior = Q1 - (1,5 * AIQ)

Maior valor antes do LS

Menor valor antes do LI

Outlier – inferior e/ou superior



BOXPLOT

Foram levantados os tempos de produção de uma determinada peça, a fim de comparar a estabilidade do processo entre os funcionários homens e mulheres, obtendo os seguintes valores em minutos.

Homens

15 – 12 – 17 – 19 – 13 – 14 – 13 – 11 – 13 – 18 – 25 – 14 - 28

Mulheres

15 – 17 – 16 – 16 – 14 – 15 – 14 – 18 – 17 – 15 – 16 – 17 - 17

BOXPLOT

Rol - Homens

15 12 17 19 13 14 13 11 13 18 25 14 28

Rol - Mulheres

14 14 15 15 15 16 16 16 17 17 17 17 18

HOMENS	
Mediana	14
Quartil 1	13
Quartil 3	18
AIQ (Amplitude interquartil) = Q3 – Q1	5
LS (limite superior = Q3 + (1,5 * AIQ)	25,5
LI (limite inferior = Q1 - (1,5 * AIQ)	5,5
Maior valor antes do LS	25
Menor valor antes do LI	11
Outlier – inferior e/ou superior	28

MULHERES	
Mediana	16
Quartil 1	15
Quartil 3	17
AIQ (Amplitude interquartil) = Q3 – Q1	2
LS (limite superior = Q3 + (1,5 * AIQ)	20
LI (limite inferior = Q1 - (1,5 * AIQ)	12
Maior valor antes do LS	18
Menor valor antes do LI	14
Outlier – inferior e/ou superior	-

Rol - Homens

11 – 12 – 13 – 13 – 13 – 14 – 14 – 15 – 17 – 18 – 19 – 25 - 28

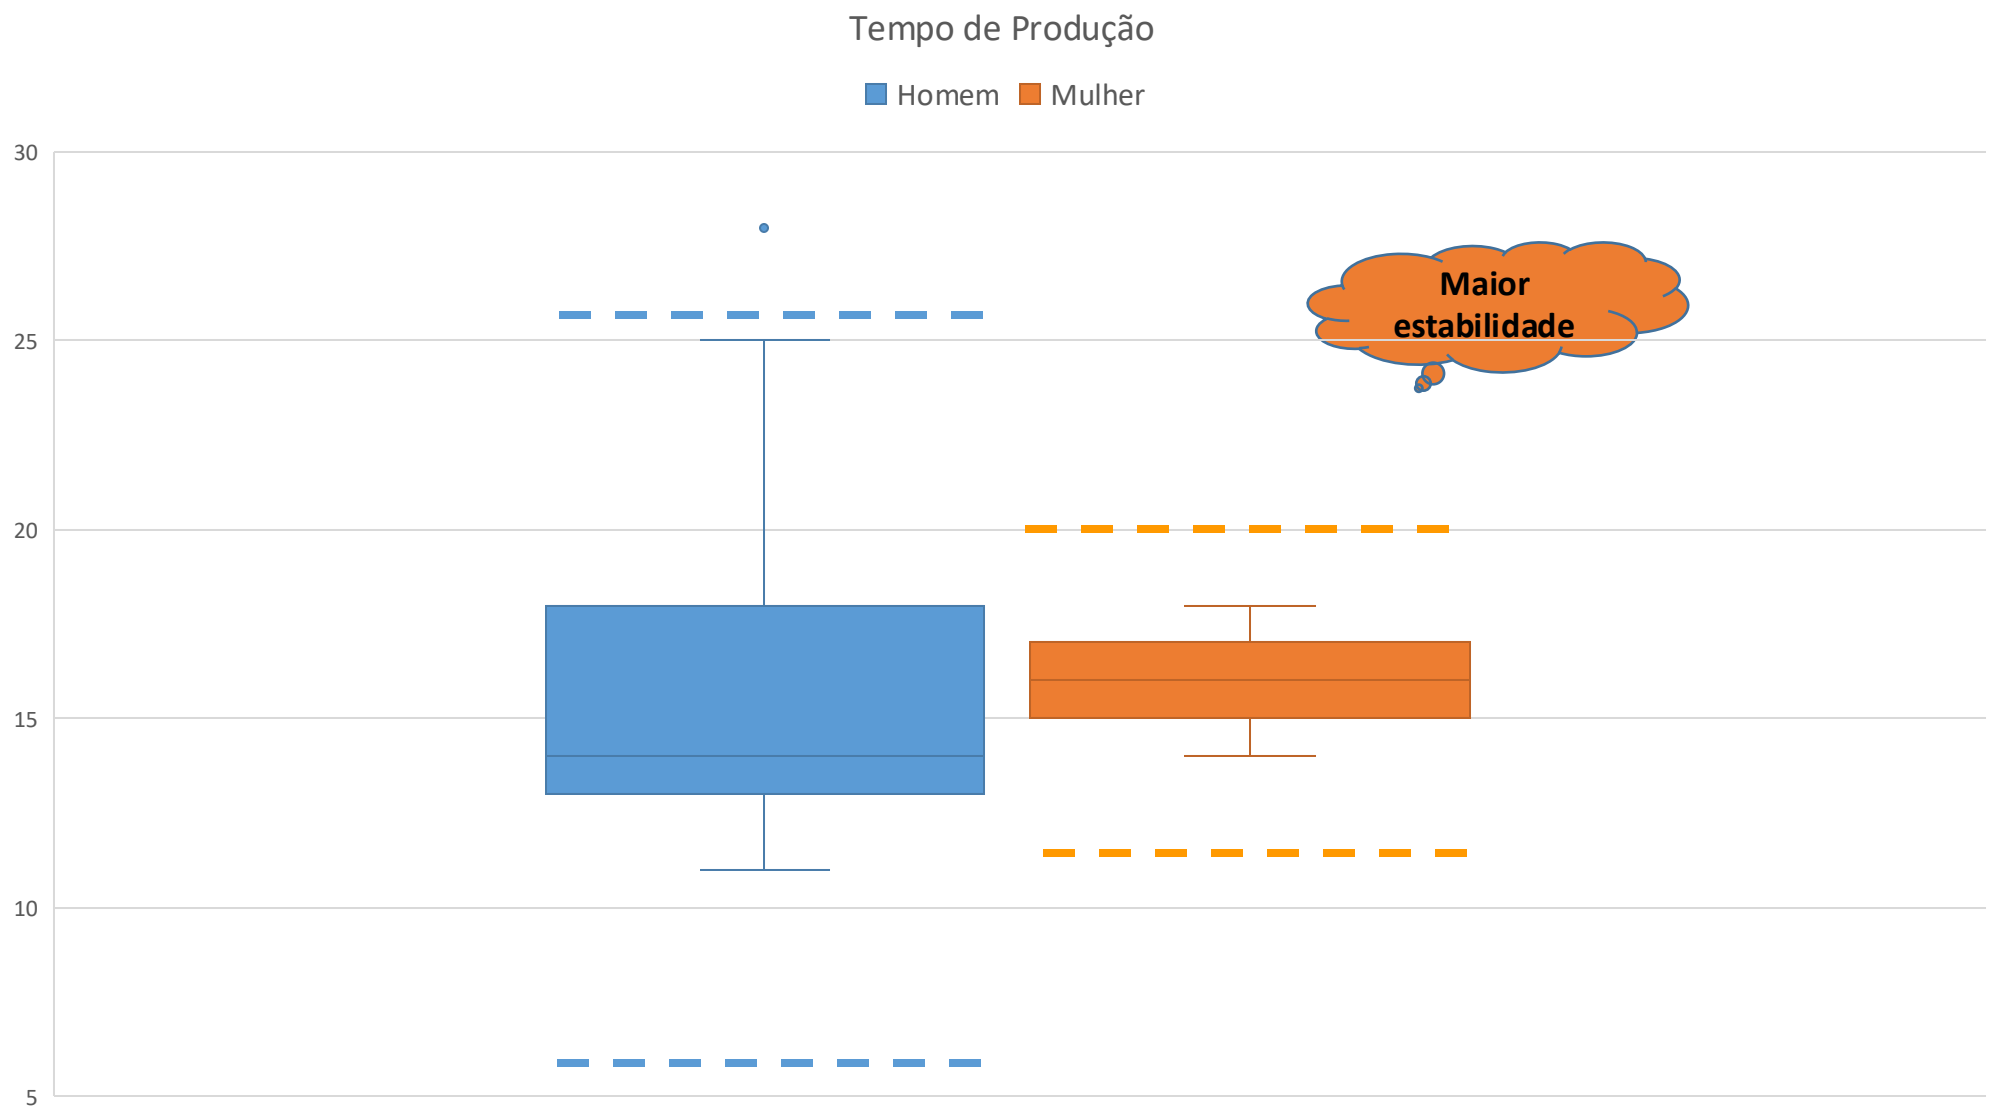
Rol - Mulheres

14 – 14 – 15 – 15 – 15 – 16 – 16 – 16 – 17 – 17 – 17 – 17 - 18

HOMENS	
Mediana	14
Quartil 1	13
Quartil 3	18
AIQ (Amplitude interquartil) = Q3 – Q1	5
LS (limite superior = Q3 + (1,5 * AIQ)	25,5
LI (limite inferior = Q1 - (1,5 * AIQ)	5,5
Maior valor antes do LS	25
Menor valor antes do LI	11
Outlier – inferior e/ou superior	28

MULHERES	
Mediana	16
Quartil 1	15
Quartil 3	17
AIQ (Amplitude interquartil) = Q3 – Q1	2
LS (limite superior = Q3 + (1,5 * AIQ)	20
LI (limite inferior = Q1 - (1,5 * AIQ)	12
Maior valor antes do LS	18
Menor valor antes do LI	14
Outlier – inferior e/ou superior	-

BOXPLOT

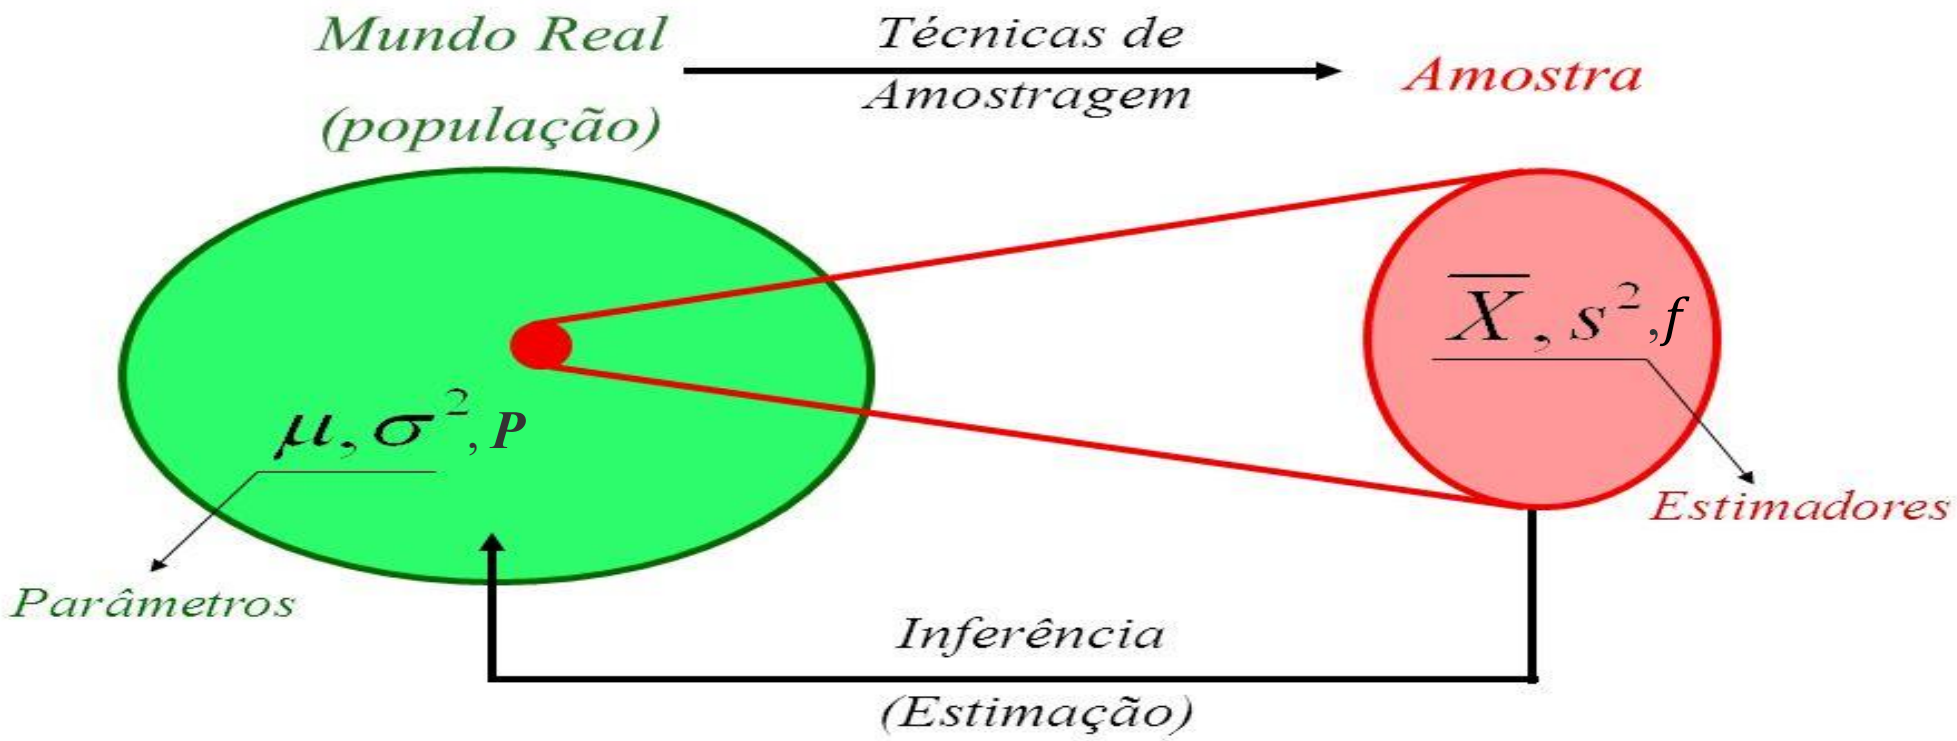

Tempo de Produção
Homem
Mulher
30
25
20
15
10
5
Maior estabilidade

Estatística Indutiva

Tem como objetivo inferir resultados para toda a população, tendo como base uma amostra



Introdução à Inferência Estatística



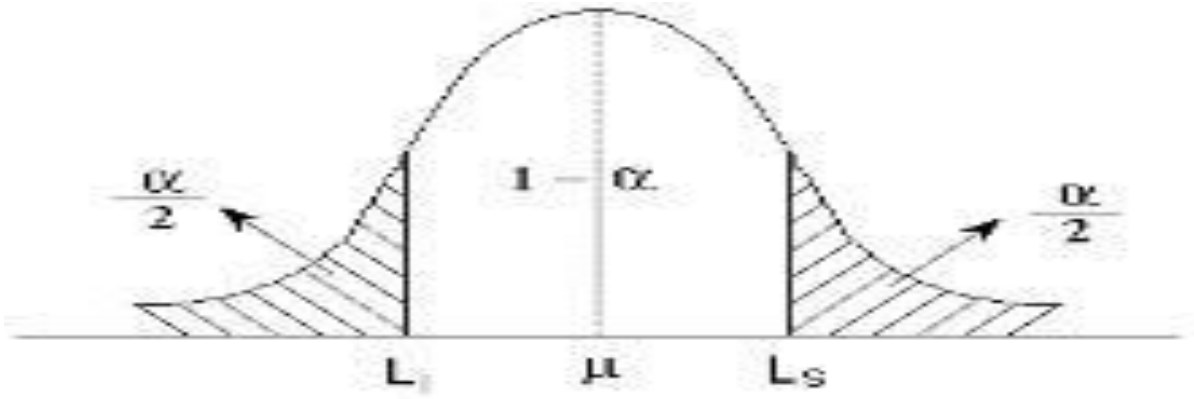
ESTIMAÇÃO

Pontual

Quando a partir de uma amostra procura-se obter
um valor de certo parâmetro populacional

Por intervalo

Quando a partir da amostra se constrói um intervalo de confiança com certa probabilidade de conter o verdadeiro parâmetro populacional



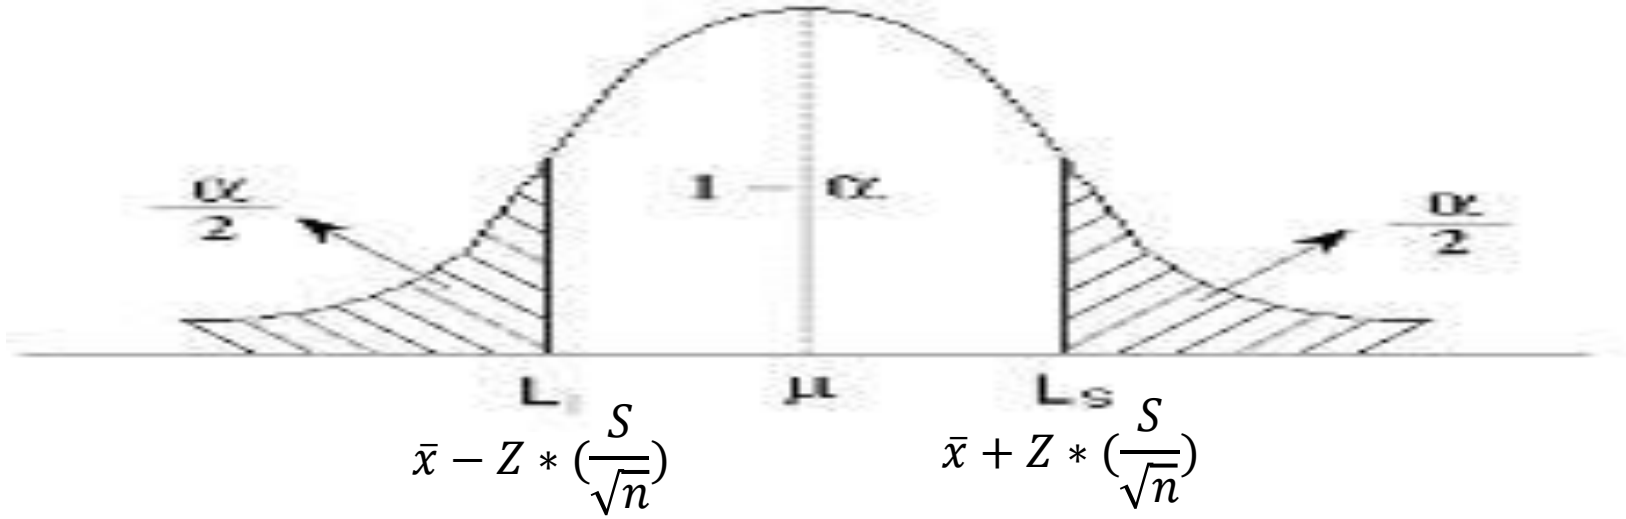
ESTIMAÇÃO

ESTIMATIVA DA MÉDIA POPULACIONAL (μ)

Pontual: $\bar{x} = \frac{\sum(\mathrm{X})}{\mathrm{n}}$ **OU** $\bar{x} = \frac{\sum(X*\mathrm{F})}{\sum(\mathrm{F})}$

Por intervalo: $IC = \bar{x} \pm Z * (\frac{S}{\sqrt{n}})$

Onde Z = Fator de probabilidade que depende do nível de confiança desejado



$\bar{x} - Z * (\frac{S}{\sqrt{n}})$ $\bar{x} + Z * (\frac{S}{\sqrt{n}})$

ESTIMAÇÃO

ESTIMATIVA DA MÉDIA POPULACIONAL (μ)

Foram feitas medições (em minutos) do tempo gasto para a fabricação de certo componente industrial, obtendo-se os seguintes resultados: Qual o tempo médio de fabricação?

12	15	13	15	14	16	15	14	15	17	15
13	14	17	15	16	13	16	17	15	17	16
14	16	14	15	14	15	16	14	15	12	16

$$\bar{x} = \frac{\sum(x)}{n} = 14{,}9 \text{ minutos}$$

ESTIMAÇÃO

ESTIMATIVA DA MÉDIA POPULACIONAL (μ)

Qual o tempo médio de fabricação considerando um N/C de 95%?

X	F	(X ∗ F)	F∗(x- $\bar{x}$) ²
12	2	24	16,82
13	3	39	10,83
14	7	98	5,67
15	10	150	0,10
16	7	112	8,47
17	4	68	17,64
∑	33	491	59,53

$$\bar{x} = \frac{\sum(X * \mathrm{F})}{\sum(\mathrm{F})} = \frac{491}{33} = 14{,}9 \text{ minutos}$$

$$S = \sqrt{\frac{\sum[\mathrm{F} * (\mathrm{x} - \bar{x})^2]}{\mathrm{n} - 1}} = \sqrt{\frac{59{,}53}{33-1}} = 1{,}36 \text{ minutos}$$

$$IC = \bar{x} \pm Z * \left(\frac{S}{\sqrt{n}}\right)$$

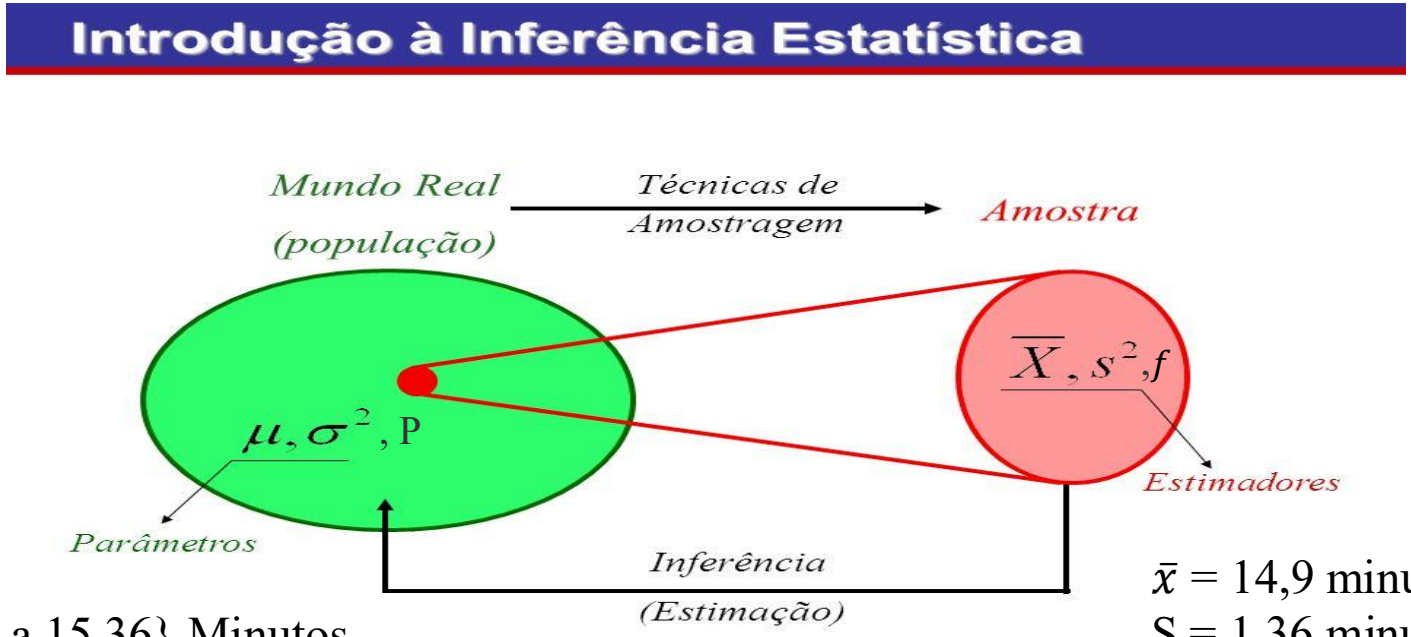
$$IC = 14{,}9 \pm 1{,}96 * \left(\frac{1{,}36}{\sqrt{33}}\right)$$

$$\boldsymbol{IC} = \{14{,}43 \text{ a } 15{,}36\} \text{ Minutos}$$

ESTIMAÇÃO

ESTIMATIVA DA MÉDIA POPULACIONAL (μ)

Qual o tempo médio de fabricação considerando um N/C de 95%?



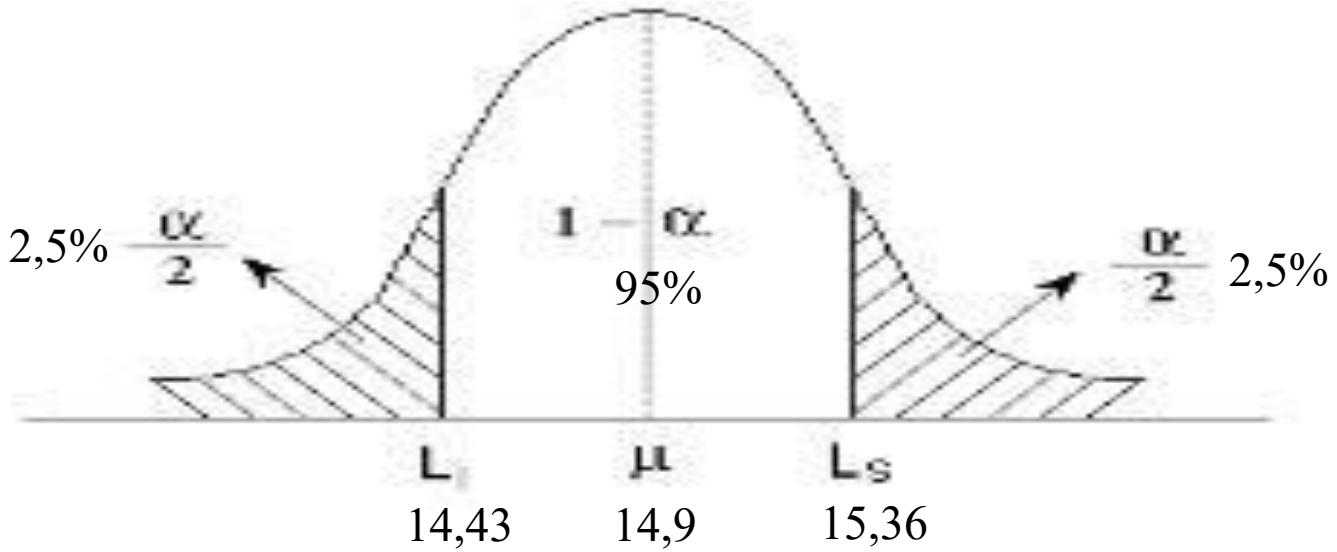
{14,43 a 15,36} Minutos

$\bar{x}$ = 14,9 minutos
S = 1,36 minutos

ESTIMAÇÃO

ESTIMATIVA DA MÉDIA POPULACIONAL (μ)

Qual o tempo médio de fabricação considerando um N/C de resposta de 95%?



TAMANHO DA AMOSTRA

PARA ESTIMATIVA DA MÉDIA POPULACIONAL (μ)

Qual o tamanho da amostra?



TAMANHO DA AMOSTRA

PARA ESTIMATIVA DA MÉDIA POPULACIONAL (μ)

O tamanho da amostra é suficiente para estimar o tempo médio de fabricação considerando um Nível de Confiança (N/C) de 95%, e um erro (e) máximo de 0,5 minutos?

e = Erro da estimativa ou diferença máxima desejada entre / μ - $\bar{x}$ /

$$n = \left(\frac{Z * S}{e}\right)^2$$

$$\boldsymbol{n = \left(\frac{1{,}96 * 1{,}36}{0{,}5}\right)^2 = 28 \text{ unidades}}$$

Portanto a resposta é sim pois seriam necessários 28 ,
sendo que foram consideradas 33 unidades

$$\text{Prova real} = \text{Erro da estimativa} = \text{Z} * \left(\frac{\text{S}}{\sqrt{\text{n}}}\right)$$

$$\boldsymbol{\text{Prova real} = \text{Erro da estimativa} = 1{,}96 * \left(\frac{1{,}36}{\sqrt{28}}\right) = 0{,}5 \text{ minutos}}$$

TAMANHO DA AMOSTRA

TAMANHO DA AMOSTRA PARA ESTIMATIVA DA MÉDIA POPULACIONAL (μ)
QUANDO A POPULAÇÃO É FINITA

Sabendo-se que o **lote de produção é de 100 unidades**, qual o tamanho da amostra para estimar o tempo médio de fabricação considerando um Nível de Confiança (N/C) de 95%, e um erro (e) máximo de 0,5 minutos?

Quando considerar a população finita?

$$\left(\frac{n=amostra\ calculada\ para\ população\ infinita}{N=População}\right) > 5\%$$

$$\left(\frac{n=28}{N=100}\right) = 28\%$$

Portanto um lote de 100 unidades considera-se população finita

TAMANHO DA AMOSTRA

PARA ESTIMATIVA DA MÉDIA POPULACIONAL (μ)
QUANDO A POPULAÇÃO É FINITA

Sabendo-se que o **lote de produção é de 100 unidades**, qual o tamanho da amostra para estimar o tempo médio de fabricação considerando um Nível de Confiança (N/C) de 95%, e um erro (e) máximo de 0,5 minutos?

$$n = \left(\frac{n(c) * N}{n(c) + N - 1}\right)$$ onde N é a população e n(c) é a amostra para população infinita

$$n = \left(\frac{28 * 100}{28 + 100 - 1}\right) = 22\ unidades$$

$$\text{Prova real} = \text{Erro da estimativa} = Z * \left(\frac{S}{\sqrt{n}}\right) * \sqrt{\frac{N-n}{N-1}}$$

Fator de correção quando a população é finita

$$\mathbf{Prova\ real = Erro\ da\ estimativa = 1,96 * \left(\frac{1,36}{\sqrt{22}}\right) * \sqrt{\frac{100-22}{100-1}} = 0,5\ minutos}$$

ESTIMAÇÃO

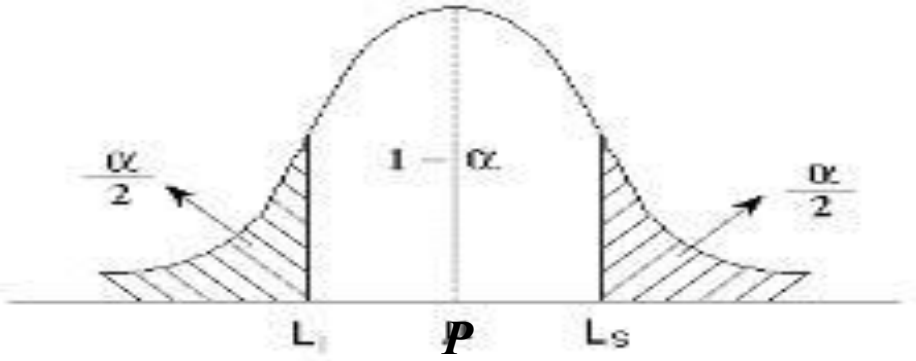
ESTIMATIVA DA PROPORÇÃO (P)

Pontual: $f\% = \frac{f(\text{absoluta})}{\Sigma(f)} * 100$

Margem de erro

Por intervalo: $IC = f\% \pm Z * \sqrt{\frac{f\% * q\%}{n}}$

Onde Z = Fator de probabilidade que depende do N/C desejado



ESTIMAÇÃO

ESTIMATIVA PROPORÇÃO POPULACIONAL (P)

No lançamento de um novo produto foi feita uma pesquisa com uma amostra de 500 pessoas para uma população de 200.000 prováveis compradores, obtendo-se os seguintes resultados: 280 gostaram, 120 não gostaram e 100 não opinaram.

Pontual: $f\% = \frac{280}{500} * 100 = 56\%$

ou

200.000 * 0,56 = 112.000 prováveis compradores

ESTIMAÇÃO

ESTIMATIVA DA PROPORÇÃO POPULACIONAL (P)

Qual a proporção de prováveis compradores com um N/C de 95%?

Margem de erro

Por intervalo: $IC = f\% \pm Z * \sqrt{\frac{f\% * q\%}{n}}$

$$IC = 0{,}56 \pm 1{,}96 * \sqrt{\frac{0{,}56 * 0{,}44}{500}}$$

$$\boldsymbol{IC} = \{51{,}65\% \ ; \ 60{,}35\%\}$$

Em quantidade de compradores...

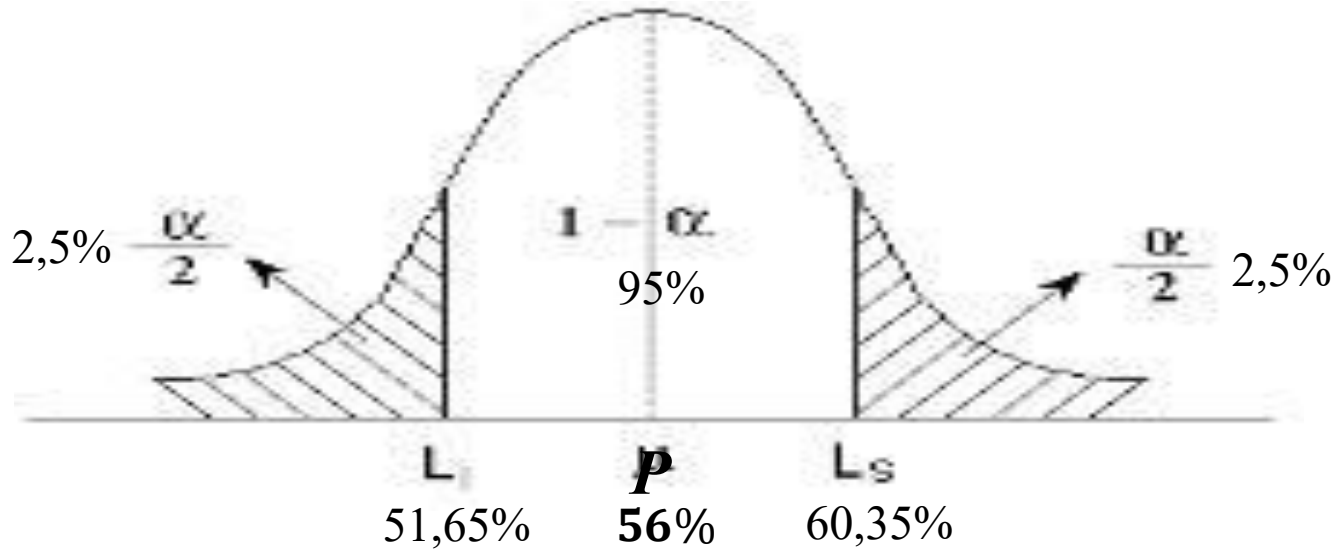
0,5165 * 200.000 = 103.300

0,6035 * 200.000 = 120.700

ESTIMAÇÃO

ESTIMATIVA DA PROPORÇÃO POPULACIONAL (P)

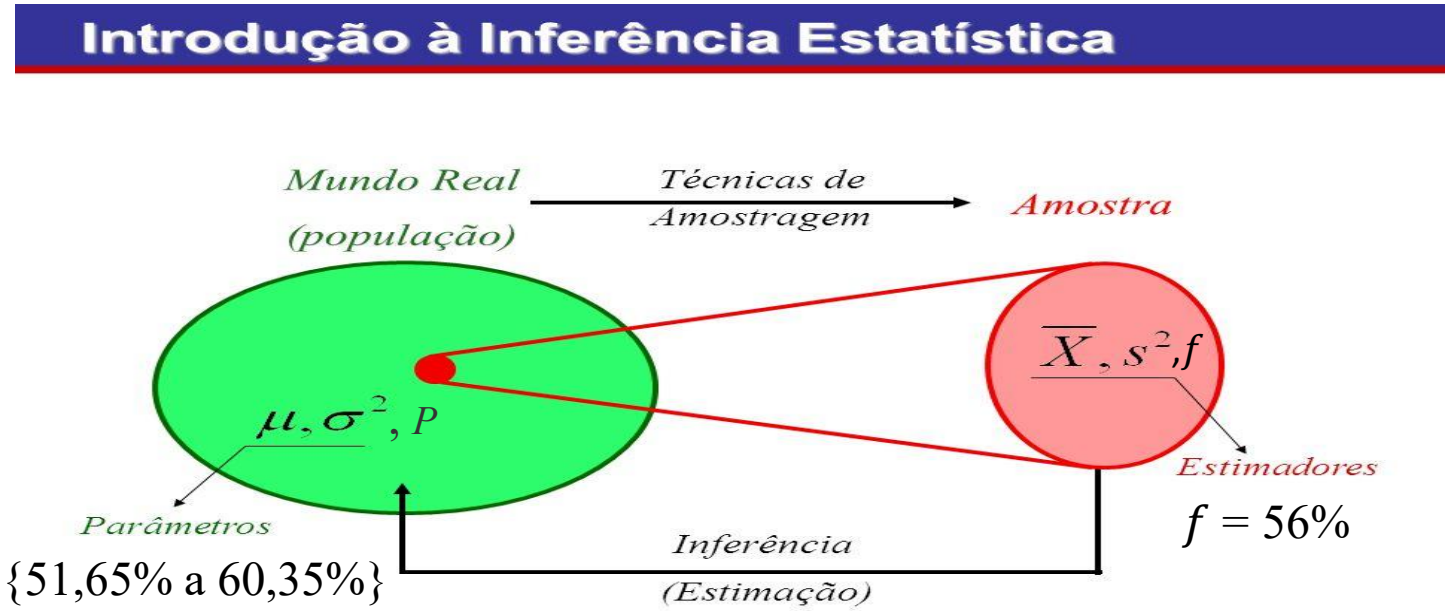
Qual a proporção de prováveis compradores com um N/C de 95%?



ESTIMAÇÃO

ESTIMATIVA DA PROPORÇÃO POPULACIONAL (P)

Qual proporção de prováveis compradores com um N/C de 95%?



{51,65% a 60,35%}

ESTIMAÇÃO

ESTIMATIVA DA PROPORÇÃO POPULACIONAL (P)

Pesquisa de intenção de votos para presidente
da república entre candidato A e B

N = 147.306.295

n = 2401

Votam no A = 1008

Votam no B = 936

Brancos e Nulos = 457

Estimativa pontual

A = 1008/2.401 = 42%

B = 936/2.401 = 39%

ESTIMAÇÃO

ESTIMATIVA DA PROPORÇÃO POPULACIONAL (P)

Pesquisa de intenção de votos para presidente
da república entre os candidatos A e B Considerando um N/C de 95%

$$IC(\mathrm{A}) = 0{,}42 \pm 1{,}96 * \sqrt{\frac{0{,}42 * 0{,}58}{2.401}}$$

{40% a 44%}

$$IC(\mathrm{B}) = 0{,}39 \pm 1{,}96 * \sqrt{\frac{0{,}39 * 0{,}61}{2.401}}$$

{37% a 41%}

Empate técnico entre os candidatos

TAMANHO DA AMOSTRA

PARA ESTIMATIVA DA PROPORÇÃO POPULACIONAL (P)

O tamanho da amostra é suficiente para estimar proporção de prováveis compradores considerando: Nível de Confiança (N/C) de 95%, e margem de erro (e) de 2%?

e = Erro da estimativa ou diferença máxima desejada entre / P - f /

$$n = \left(\frac{Z}{e}\right)^2 * f\% * q\%$$

$$\boldsymbol{n = \left(\frac{1{,}96}{0{,}02}\right)^2 * 0{,}56 * 0{,}44 \quad = \ 2.367 \text{ elementos}}$$

A a resposta é não, pois seriam necessários 2.367, sendo que foram considerados 500 elementos

$$\text{Prova real} = \text{Erro da estimativa} = Z * \sqrt{\frac{f\% * q\%}{n}}$$

$$\boldsymbol{\text{Prova real} = \text{Erro da estimativa} = 1{,}96 * \sqrt{\frac{0{,}56 * 0{,}44}{2.367}} = 2\%}$$

TAMANHO DA AMOSTRA

PARA ESTIMATIVA DA PROPORÇÃO POPULACIONAL (*P*)
QUANDO A POPULAÇÃO É FINITA

Sabendo-se que **a população é de 30.000 pessoas**, qual o tamanho da amostra para estimar o a proporção de prováveis compradores, considerando um Nível de Confiança (N/C) de 95%, e um erro (e) máximo de 2%?

$$n = \left(\frac{n(c) * N}{n(c) + N - 1}\right)$$ onde N é a população e n(c) é a amostra para população infinita

$$n = \left(\frac{2.367 * 30.000}{2.367 + 30.000 - 1}\right) = 2.194\ elementos$$

$$\text{Prova real} = \text{Erro da estimativa} = Z * \sqrt{\frac{f\% * q\%}{\text{n}}} * \sqrt{\frac{\text{N} - \text{n}}{\text{N} - 1}}$$

Fator de correção quando a população é finita

$$\mathbf{Prova\ real = Erro\ da\ estimativa = 1,96 * \sqrt{\frac{0,56 * 0,44}{2.194}} * \sqrt{\frac{30.000 - 2.194}{30.000 - 1}} = 2\%}$$

ANÁLISE BIVARIADA

Em muitos casos a análise isolada de cada uma das variáveis não é a única forma de entender o comportamento dos dados, portanto é interessante a análise conjunta dos dados, associando-os, a fim de se verificar a dependência entre eles. A análise bivariada pode ser entre variáveis:

Quantitativa X Quantitativa

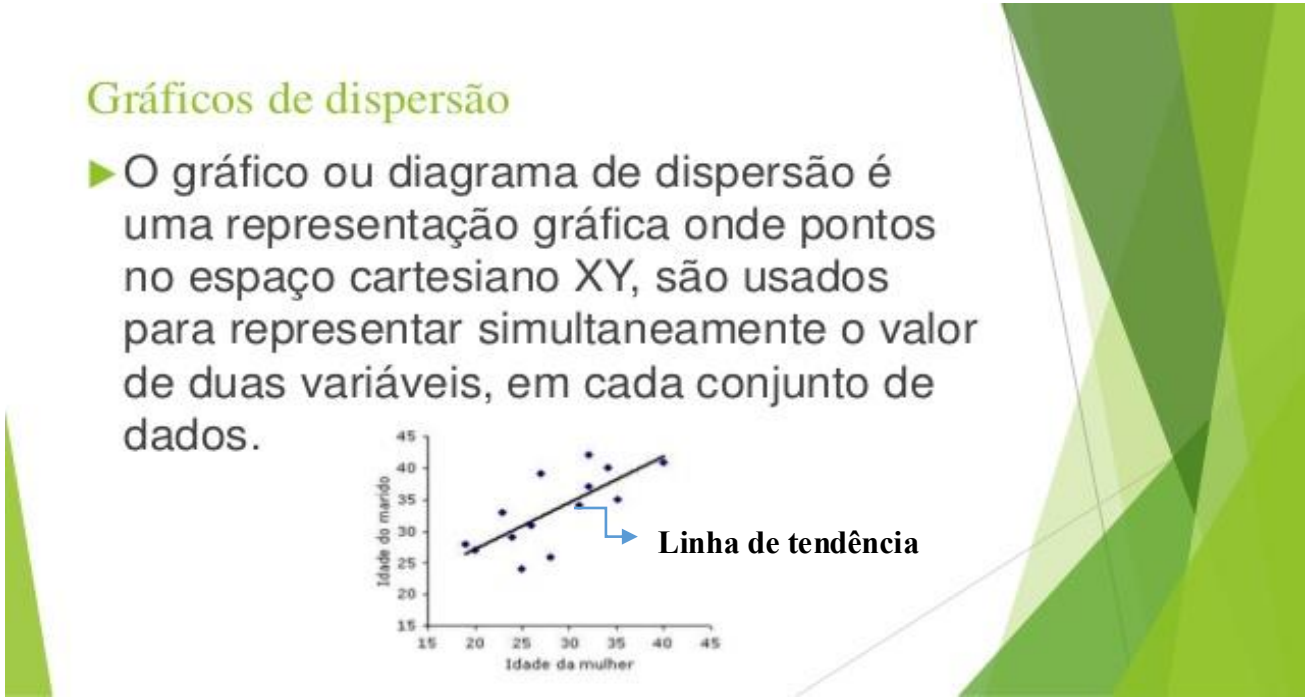
Qualitativa X Qualitativa

Qualitativa X Quantitativa

ANÁLISE BIVARIADA

Correlação entre variáveis Quantitativas

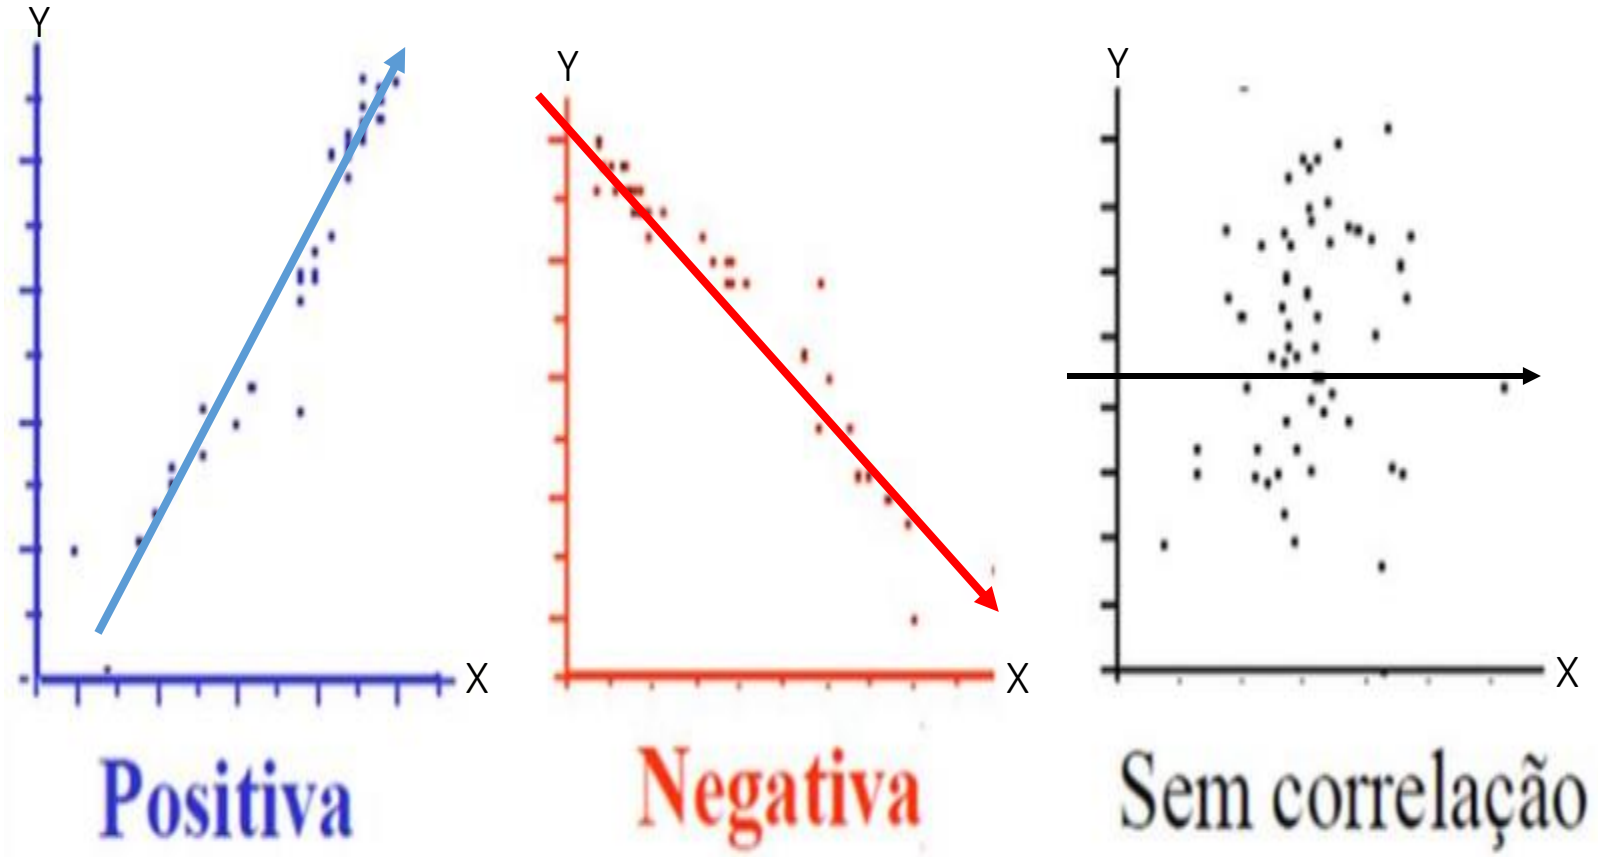
Dizemos que existe correlação entre variáveis quantitativas quando a medida que alteramos o valor da variável independente (X), altera-se o valor da variável dependente (Y). A verificação da correlação , de maneira gráfica, se dá pelo diagrama de dispersão.



ANÁLISE BIVARIADA

Correlação entre variáveis Quantitativas

A partir do diagrama de dispersão a correlação pode ser classificada em:



ANÁLISE BIVARIADA

Correlação entre variáveis Quantitativas

A verificação da correlação, de maneira algébrica, se dá pelo coeficiente de correlação, que é uma medida de correlação entre duas variáveis utilizadas a fim de saber a **intensidade** da correlação, sendo dado por:

$$r = \frac{COV}{\sigma(x) * \sigma(y)}$$

ANÁLISE BIVARIADA

Correlação entre variáveis Quantitativas

r = Coeficiente de correlação $\frac{\text{COV}}{\sigma(\text{x})*\sigma(\text{y})}$

COV = Covariância $\frac{\sum[(\text{X}-\bar{X})*(\text{Y}-\bar{Y})]}{\text{n}}$

$\sigma(\text{x})$ = Desvio padrão de (x) $\sqrt{\frac{\sum(\text{x}-\mu\ de\ x)^2]}{\text{n}}}$

$\sigma(y)$ = Desvio padrão de (y) $\sqrt{\frac{\sum(\text{y}-\mu\ de\ y)^2]}{\text{n}}}$

Se r (x,y)
- = 1 ➡ Correlação positiva perfeita
- = - 1 ➡ Correlação negativa perfeita
- = 0 ➡ Correlação nula

ANÁLISE BIVARIADA

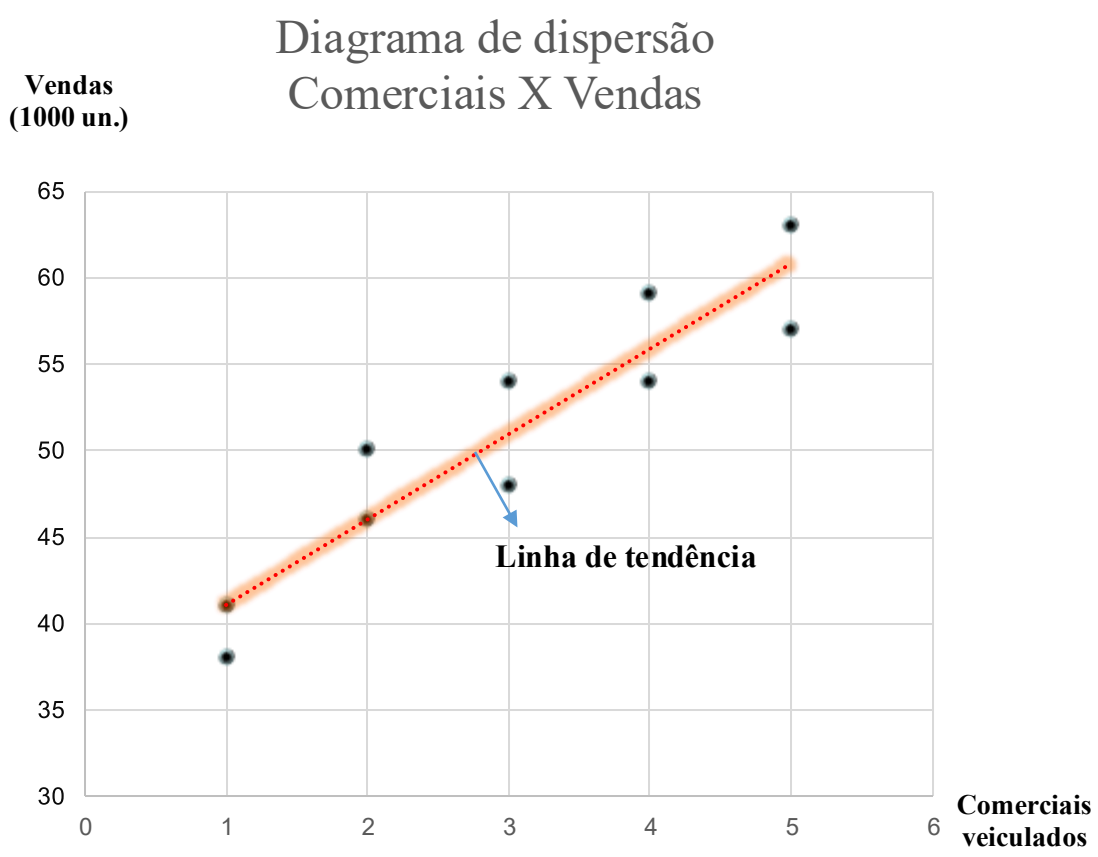
Correlação entre variáveis Quantitativas
Exemplo de aplicação

Semana	Comerciais veiculados	Vendas (1000 un.)
1	2	50
2	5	57
3	1	41
4	3	54
5	4	54
6	1	38
7	5	63
8	3	48
9	4	59
10	2	46

ANÁLISE BIVARIADA

Correlação entre variáveis Quantitativas

Semana	Comerciais veiculados	Vendas (1000 un.)
1	2	50
2	5	57
3	1	41
4	3	54
5	4	54
6	1	38
7	5	63
8	3	48
9	4	59
10	2	46



ANÁLISE BIVARIADA

Coeficiente de Correlação $r = \frac{COV}{\sigma(x)*\sigma(y)} = \frac{9,9}{1,4*7,5} = 94,3\%$

Média de x = 3
Média de y = 51

$COV = \frac{\sum[(X-\bar{X})*(Y-\bar{Y})]}{n} = \frac{99}{10} = 9,9$

$\sigma(x) = \sqrt{\frac{20}{10}} = 1,4$

$\sigma(y) = \sqrt{\frac{566}{10}} = 7,5$

	X	Y	$(x-\bar{x})$	$(y-\bar{y})$	$\{(x-\bar{x})*(y-\bar{y})\}$	$(x-\bar{x})^2$	$(y-\bar{y})^2$
	2	50	-1	-1	1	1	1
	5	57	2	6	12	4	36
	1	41	-2	-10	20	4	100
	3	54	0	3	0	0	9
	4	54	1	3	3	1	9
	1	38	-2	-13	26	4	169
	5	63	2	12	24	4	144
	3	48	0	-3	0	0	9
	4	59	1	8	8	1	64
	2	46	-1	-5	5	1	25
∑	30	510	0	0	99	20	566

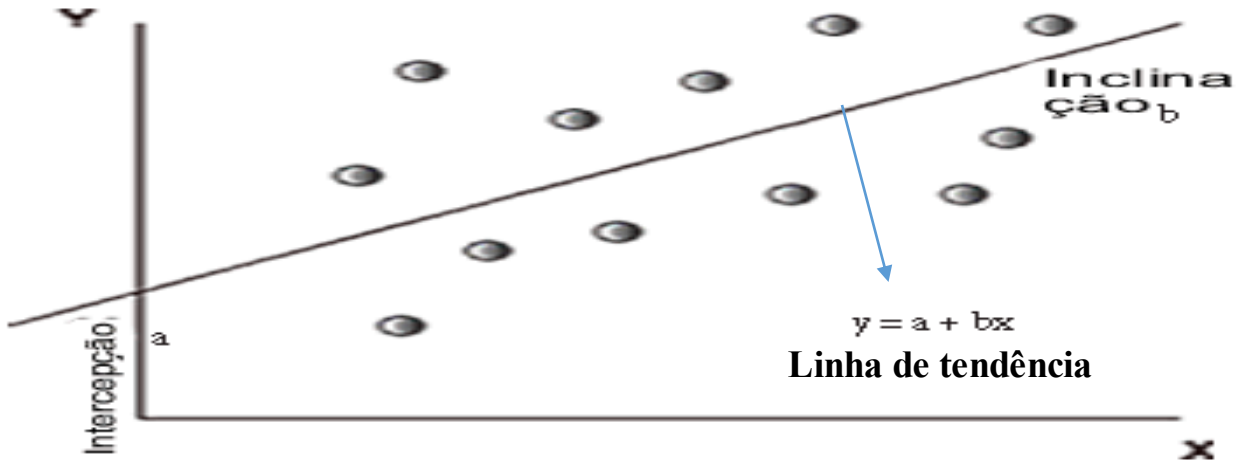
ANÁLISE BIVARIADA

Regressão Linear

Existindo correlação entre as variáveis podemos fazer previsão da variável dependente (Y) com base na variável independente (X), para tanto precisamos encontrar a reta de regressão da correlação, que é a linha imaginária que passa entre os pontos no diagrama de dispersão, dando o sentido da correlação, e é dada pela seguinte função: $\mathbf{Y = a + b * (x)}$, sendo (a) e (b) obtidos pelas equações normais, dadas por:

$$\sum \boldsymbol{y} = \boldsymbol{n} * (\boldsymbol{a}) + (\boldsymbol{b}) * (\sum \boldsymbol{x})$$

$$\sum (\boldsymbol{x} * \boldsymbol{y}) = (\boldsymbol{a}) * (\sum \boldsymbol{x}) + (\boldsymbol{b}) * (\sum \boldsymbol{x^2})$$



ANÁLISE BIVARIADA

Regressão Linear

Qual a previsão de vendas se o número de comerciais veiculados por semana for igual a sete?

	X	Y	(X*Y)	x^2
	2	50	100	4
	5	57	285	25
	1	41	41	1
	3	54	162	9
	4	54	216	16
	1	38	38	1
	5	63	315	25
	3	48	144	9
	4	59	236	16
	2	46	92	4
Σ	30	510	1629	110

$$\sum \boldsymbol{y} = \boldsymbol{n} * (\boldsymbol{a}) + (\boldsymbol{b}) * (\sum \boldsymbol{x})$$

$$\sum (\boldsymbol{x} * \boldsymbol{y}) = (\boldsymbol{a}) * (\sum \boldsymbol{x}) + (\boldsymbol{b}) * \left(\sum \boldsymbol{x^2}\right)$$

$$\mathbf{Y} = \mathbf{a} + \mathbf{b} * (\mathbf{x})$$

Y = 36,15 + 4,95 * (7) = 70,8 mil unidades

Qual a previsão de vendas se o número de comerciais veiculados por semana for igual a sete?

	Comerciais (X)	Vendas (Y)	(X*Y)	x^2
	2	50	100	4
	5	57	285	25
	1	41	41	1
	3	54	162	9
	4	54	216	16
	1	38	38	1
	5	63	315	25
	3	48	144	9
	4	59	236	16
	2	46	92	4
Σ	30	510	1629	110

$$Y = A + b * (x)$$

Y = 36,15 + 4,95 * (7) = 70,8 mil unidades

$$\sum y = n * (a) + (b) * (\sum x)$$

$$\sum (x * y) = (a) * (\sum x) + (b) * (\sum x^2)$$

{ 510 = 10 * (a) + b * (30) } * - (30/10)

510 = 10(a) + 4,95*30

510 = 10(a) + 148,5

510 – 148,5 = 10(a)

361,5 = 10(a)

a = 36,15

1629 = (a) * 30 + (b) * 110)

- 1530 = (a)* -30 + (b) * - 90)

99 = b * 20

b = 4,95

PREVISÃO DE UMA SÉRIE TEMPORAL

Qual a previsão de vendas para 2020?

Ano (X)	Vendas (Y)
2014	50.000
2015	57.000
2016	41.000
2017	54.000
2018	61000
2019	59.000

X	Y
0	50
1	57
2	41
3	54
4	61
5	59

$$Y = A + b * (x)$$

$$\sum \boldsymbol{y} = \boldsymbol{n} * (\boldsymbol{a}) + (\boldsymbol{b}) * (\sum \boldsymbol{x}) \qquad \sum (\boldsymbol{x} * \boldsymbol{y}) = (\boldsymbol{a}) * (\sum \boldsymbol{x}) + (\boldsymbol{b}) * \left(\sum \boldsymbol{x^2}\right)$$

$$Y = A + b * (6)$$

Correlação envolvendo variável qualitativa

Para verificação da existência de correlação entre as variáveis utilizamos o teste Qui-Quadrado, dado por:

$$\chi^2$$

Teste do Qui-Quadrado

Roteiro

1º passo:

Fazer a tabela de dupla entrada, também chamada de tabela de contingência, obtendo as frequências observadas em cada cruzamento das variáveis.

TABELA DE CONTINGÊNCIA

Região	Mulheres	Homens	Total
Centro-Oeste	1029	2300	3329
Nordeste	1819	3960	5779
Norte	1377	3056	4433
Sudeste	2935	6607	9542
Sul	940	2061	3001
Total	8100	17984	26084

Teste do Qui-Quadrado

Roteiro

2º passo:

Calcular o χ^2 (c)

$$F(E) = \frac{(\sum \text{da linha} * \sum \text{da coluna})}{\text{Total de observações}}$$

	Variável (1)	Variável (2)	F(O)	F(E)	χ^2 (c)
∑					

$$\chi^2(c) = \sum \frac{(Fo-Fe)^2}{Fe}$$

Onde:

Fo = Frequência observada no cruzamento das variáveis

Fe = Frequência esperada no cruzamento das variáveis

TESTE DE HIPÓTESE

3º passo:

Obter o χ^2 (Tabelado) para o nível de significância ($\propto$) desejado e para os graus de liberdade (GL) especificados pela tabela de contingência,

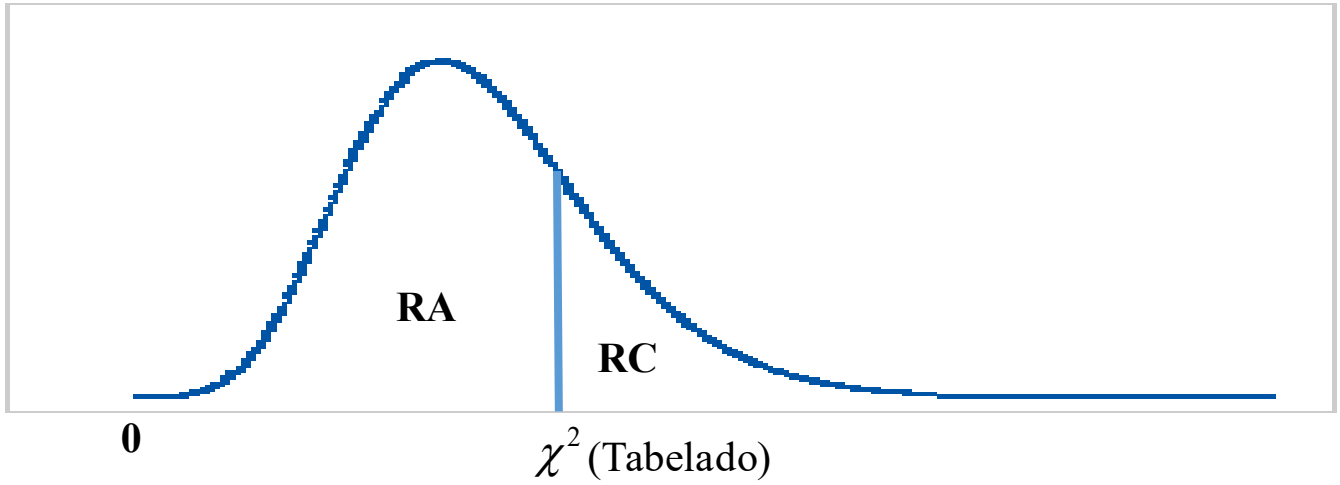
Sendo GL = (número de colunas – 1) * (número de linhas – 1)

g.l.	20%	10%	5%	2%	1%	0,1%
1	1,64	2,71	3,84	5,41	6,64	10,83
2	3,22	4,60	5,99	7,82	9,21	13,82
3	4,64	6,25	7,82	9,84	11,34	16,27
4	5,99	7,78	9,49	11,67	13,28	18,46
5	7,29	9,24	11,07	13,39	15,09	20,52
6	8,56	10,64	12,59	15,03	16,81	22,46
7	9,80	12,02	14,07	16,62	18,48	24,32
8	11,03	13,36	15,51	18,17	20,09	26,12

Teste do Qui-Quadrado

4º passo:

Verificar se χ^2 (c) está na região crítica



5º passo:

Tomada de decisão: Se o χ^2 (c) estiver na região crítica (RC), podemos afirmar , com N/C especificado, que as variáveis são **DEPENDENTES.**

Exemplo de aplicação do teste Qui-Quadrado

O diretor de crédito do banco cívico desconfia que existe uma relação entre o status do cliente (Bom ou Mal pagador) e o tipo de residência em que vive. Para confirmar sua hipótese, selecionou aleatoriamente uma amostra com 2.000 clientes, sendo a tabela de contingência dada a seguir.

Tipo de Residência em que vive	Status		Total
	Mal	Bom	
Alugada	165	264	429
Própria	399	772	1171
Outros	149	251	400
Total	713	1287	2000

Teste Qui-Quadrado

$$\chi^2\,(c) = \sum \frac{(Fo-Fe)^2}{Fe}$$

Tipo de Residência em que vive	Status		Total
	Mal	Bom	
Alugada	165	264	429
Própria	399	772	1171
Outros	149	251	400
Total	713	1287	2000

	Residência	Status	F(O)	F(E)	χ^2(c)
	Alugada	Mal	165	153	0,941
	Alugada	Bom	264	276	0,522
	Própria	Mal	399	417	0,777
	Própria	Bom	772	754	0,430
	Outros	Mal	149	143	0,252
	Outros	Bom	251	257	0,140
Σ	-	-	2.000	2.000	**3,062**

Dos 2000 clientes amostrados,713 são classificados como Mal pagador, portanto se escolhermos 429 clientes, quantos provavelmente seriam classificados como Mal pagador?

2000 -------- 713

429 -------- X

X = 153

Sendo $F(E) = \frac{(\sum \text{da linha} * \sum \text{da coluna})}{\text{Total de observações}}$

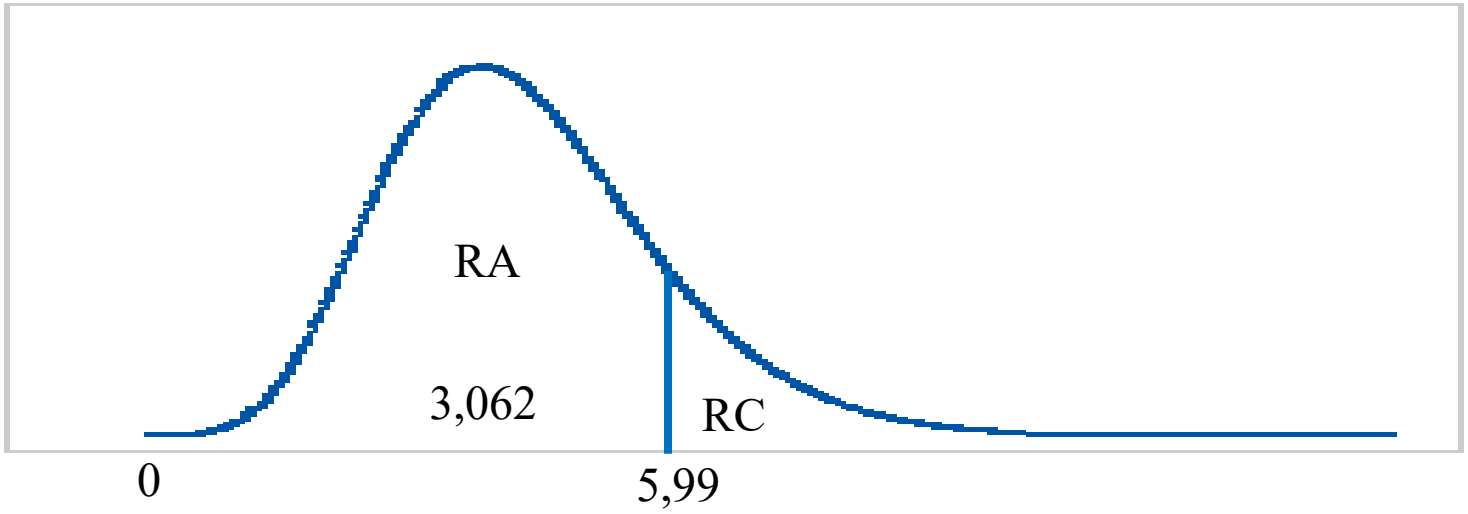
$$F(E) = \frac{429 * 713)}{2000} = 153$$

Teste Qui-Quadrado

Residência	Status		Total
	Mal	Bom	
Alugada	165	264	429
Própria	399	772	1171
Outros	149	251	400
Total	713	1287	2000

	Residência	Status	F(O)	F(E)	χ^2(c)
	Alugada	Mal	165	153	0,941
	Alugada	Bom	264	276	0,522
	Própria	Mal	399	417	0,777
	Própria	Bom	772	754	0,430
	Outros	Mal	149	143	0,252
	Outros	Bom	251	257	0,140
Σ	-	-	2.000	2.000	**3,062**

χ^2(tabelado) para N/C = 95% e $\propto$ = 5% com GL = (2-1) * (3-1) = 2 ⇨ **5,99**



Conclui-se que o status do cliente **NÃO DEPENDE** do tipo de residência

Teste Qui-Quadrado

O diretor de MKT de uma fábrica de refrigerante quer saber se existe dependência entre a faixa etária dos clientes e o sabor dos refrigerantes com uma certeza de resposta de 90%, para tanto fez o levantamento a seguir:

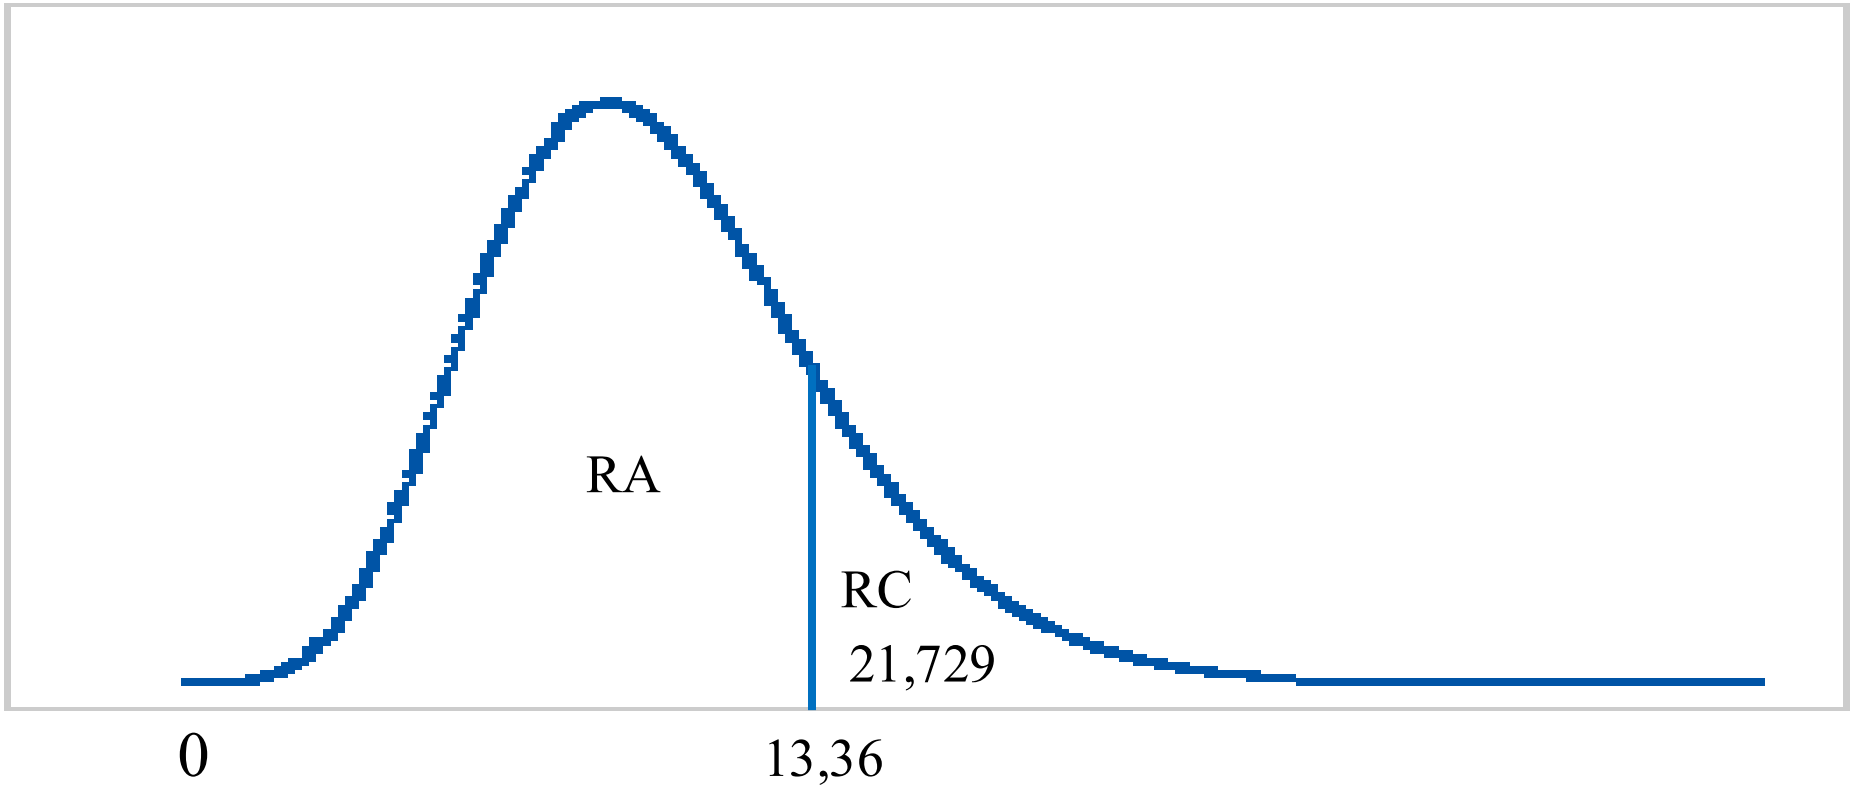
Faixa etária (anos)	Sabor			Total
	Cola	Laranja	Limão	
10/-----20	25	15	30	70
20/-----30	35	20	15	70
30/-----40	20	13	10	43
40/-----50	15	10	12	37
50/-----60	7	5	20	32
∑	102	63	87	252

Teste Qui-Quadrado

Faixa etária (anos)	Sabor			Total
	Cola	Laranja	Limão	
10/-----20	25	15	30	70
20/-----30	35	20	15	70
30/-----40	20	13	10	43
40/-----50	15	10	12	37
50/-----60	7	5	20	32
∑	102	63	87	252

Faixa Etária	Sabor	F(O)	F(E)	χ^2 (c)
10/------20	Cola	25	28,3	0,385
10/------20	Laranja	15	17,5	0,357
10/------20	Limão	30	24,2	1,390
20/------30	Cola	35	28,3	1,586
20/------30	Laranja	20	17,5	0,357
20/------30	Limão	15	24,2	3,498
30/------40	Cola	20	17,4	0,389
30/------40	Laranja	13	10,8	0,448
30/------40	Limão	10	14,8	1,557
40/------50	Cola	15	15,0	0,000
40/------50	Laranja	10	9,3	0,588
40/------50	Limão	12	12,8	0,050
50/------60	Cola	7	12,9	2,698
50/------60	Laranja	5	8,0	1,125
50/------60	Limão	20	11,0	7,364
∑	-	252	252	**21,792**

χ^2 (tabelado) para N/C = 90% com GL = (5-1) * (3-1) = 8 ➡ **13,362**



Concluímos que a preferência pelo sabor **DEPENDE** da faixa etária

TESTE DE HIPÓTESE

Teste de hipótese para parâmetro populacional

Os testes de hipótese representam uma regra que permite aceitar ou não uma hipótese questionada a respeito de um parâmetro populacional, decisão esta, que é tomada em função do estimador obtido na amostra.

Admite-se inicialmente um valor hipotético para o parâmetro e a seguir baseando-se no problema define-se as hipóteses dadas por:

HIPÒTESE NULA (H0): É aquela que será testada, admitindo-se aqui que a diferença observada entre o estimador e o parâmetro é devida apenas ao acaso, ou seja, a diferença não é significativa. Sempre para H0 considera-se a IGUALDADE, podendo ser:

$$\text{H0: Parâmetro: } \begin{cases} = \text{Valor} \\ > = \text{Valor} \\ < = \text{Valor} \end{cases}$$

HIPÒTESE ALTERNATIVA (H1): É aquela hipótese diferente da nula, isto é, aquela que será aceita caso o teste indique que H0 deva ser rejeitada, concluindo-se que a diferença entre o estimador e o parâmetro é significativa.

TESTE DE HIPÓTESE

ROTEIRO

1. Enunciar as hipóteses H0 e H1

2. Encontrar o Z (teste) com base no nível de significância (α), sendo:

$$Para\ a\ média\text{: } Z(teste) = \frac{\bar{x} - \mu}{\frac{S}{\sqrt{n}}}$$

$$Para\ a\ proporção\text{: } Z(teste) = \frac{f - P}{\sqrt{\frac{P * \mathrm{q}}{\mathrm{n}}}}$$

3. Desenhar a curva normal, indicando Z , a região crítica e de aceitação.

4. Se o valor do Z (teste) estiver na região critica, rejeita-se H0.

TESTE DE HIPÓTESE

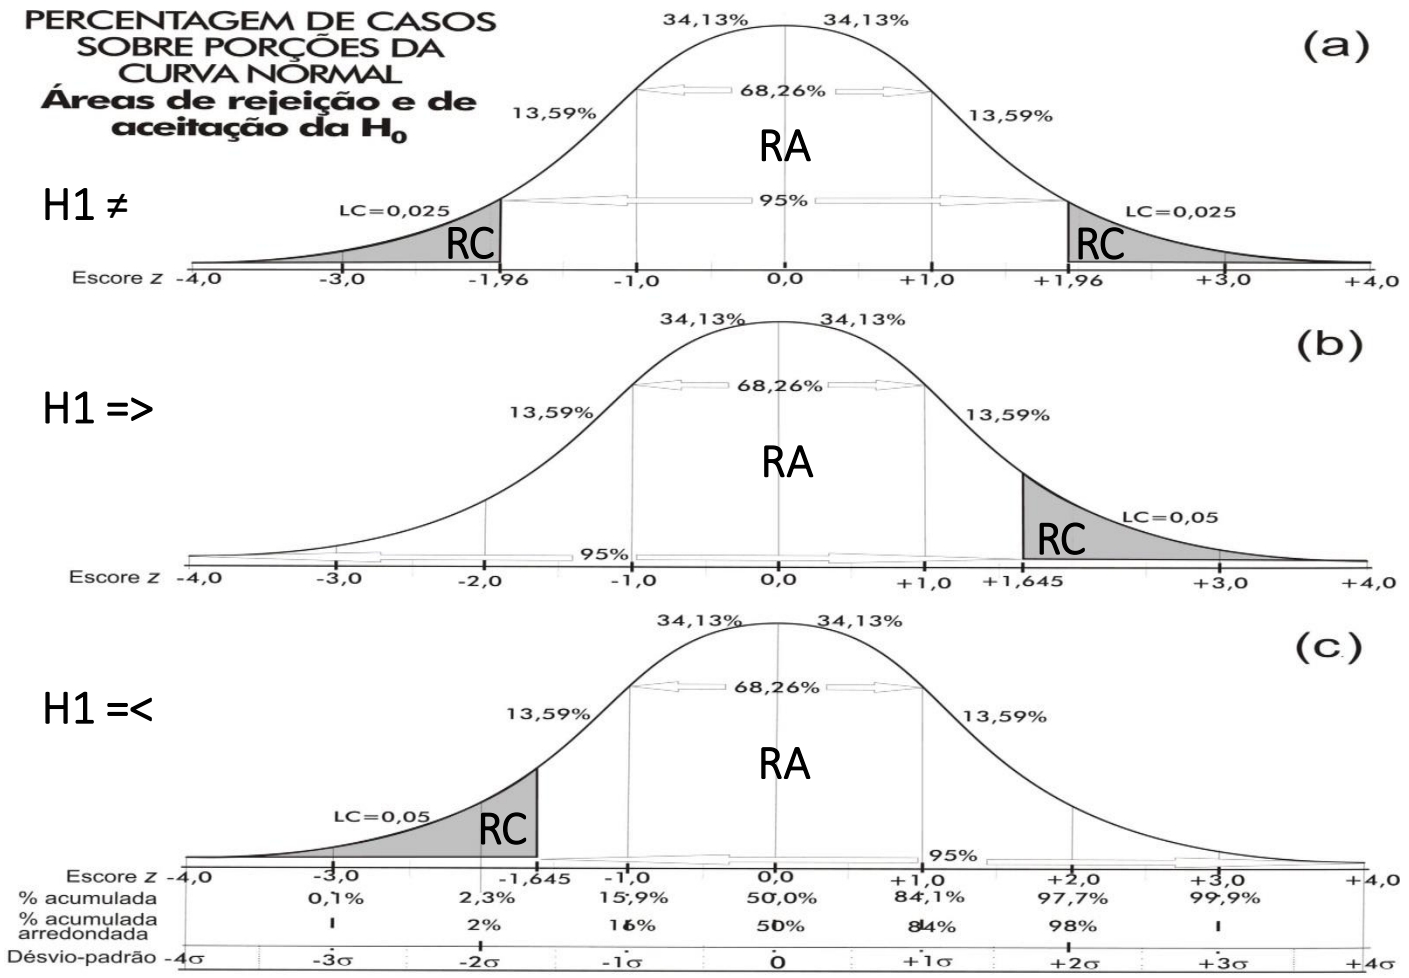


Figura 1: A distribuição normal e áreas críticas representativas de: a) um teste bicaudal; b) um teste unicaudal para resultado acima da média; c) um teste unicaudal para resultado abaixo da média da população.

TESTE DE HIPÓTESE

TESTE DE HIPÓTESE PARA A MÉDIA (μ)

Exemplo de aplicação

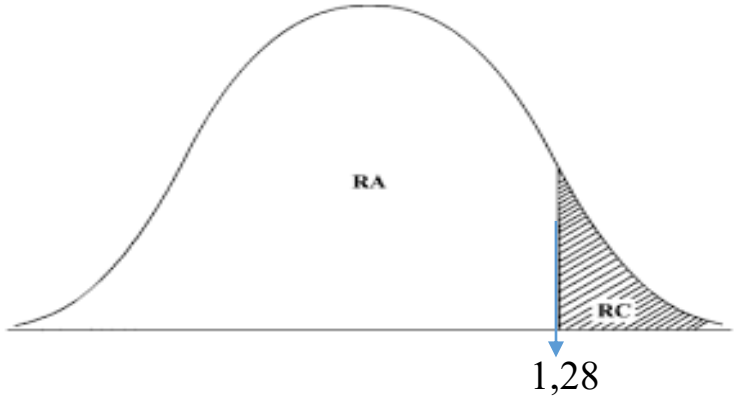
1. Segundo a ONU, os países não pertencentes ao G8 possuem um PIB per capto médio de US$ 1.250, e que após a implantação do projeto do milênio esta média aumentou. A afirmação foi feita com base em uma amostra aleatória de 49 países, onde foi encontrado um PIB médio per capto de US$ 1.400 com desvio padrão de US$ 700. Com α de 10%, esta afirmação é verdadeira?

TESTE DE HIPÓTESE

TESTE DE HIPÓTESE PARA A MÉDIA (μ)

H0: μ = 1250
H1: μ > 1250

$$Z(teste) = \frac{\bar{x} - \mu}{\frac{S}{\sqrt{n}}} = \frac{1400-1250}{\frac{700}{\sqrt{49}}} = 1{,}5$$



Teste unicaudal
N/C = 90%
α = 10%
90 – 50 = 40%

Rejeito H0, pois Z(teste) = 1,5 está na região crítica, assim podemos afirmar, com um N/C de 90% que o PIB per capto dos países não pertencentes ao G8 aumentou com a implantação do projeto do milênio.

TESTE DE HIPÓTESE

TESTE DE HIPÓTESE PARA A MÉDIA (μ)

2. A associação dos proprietários de indústrias metalúrgicas está preocupada com o tempo perdido com acidentes de trabalho cuja média nos últimos tempos tem sido da ordem de 60 horas/homem por ano com desvio padrão de 20. Tentou-se um programa de prevenção de acidentes, após o qual foi tomada uma amostra de 59 indústrias, na qual encontrou-se uma média de 50 horas/homem perdidas com acidentes. Você diria com N/C de 95% que há evidência de melhoria?

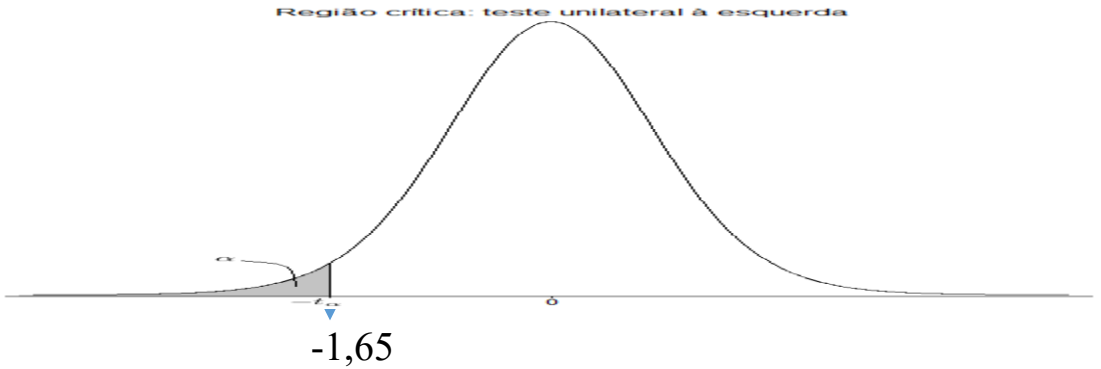
TESTE DE HIPÓTESE

TESTE DE HIPÓTESE PARA A MÉDIA (μ)

H0: $\mu = 60$

H1: $\mu < 60$

$$Z(teste) = \frac{\bar{x} - \mu}{\frac{S}{\sqrt{n}}} = \frac{50-60}{\frac{20}{\sqrt{59}}} = -3{,}8$$



-1,65

Teste unicaudal

N/C = 95%

$\alpha = 5\%$

95 – 50 = 45%

Rejeito H0, pois Z(teste) = -3,8 está na região crítica, assim podemos afirmar, com um N/C de 95% que há evidência de melhoria.

TESTE DE HIPÓTESE

TESTE DE HIPÓTESE PARA A MÉDIA (μ)

3. Determinada amostra de 35 elementos resultou uma média de 14 cm e desvio padrão de 6,4 cm. Efetuar o teste com α de 0,05 para a hipótese que a média populacional é diferente de 16.

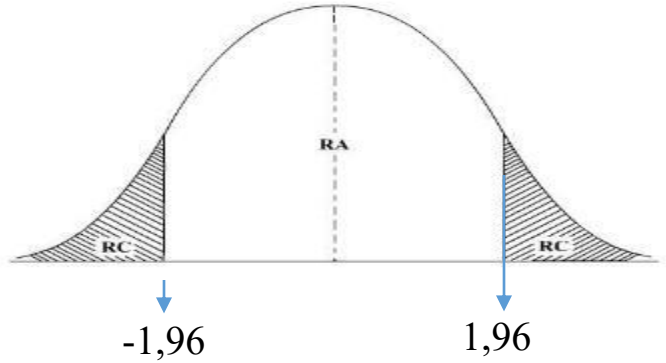
TESTE DE HIPÓTESE

TESTE DE HIPÓTESE PARA A MÉDIA (μ)

H0: $\mu = 16$

H1: $\mu \neq 16$

$$Z(teste) = \frac{\bar{x} - \mu}{\frac{S}{\sqrt{n}}} = \frac{14-16}{\frac{6,4}{\sqrt{35}}} = -1,85$$



Teste Bicaudal
N/C = 95%
$\alpha = 5\%$
95/2 = 47,5%

Aceito H0, pois Z(teste) = -1,85 está na região de aceitação, assim podemos afirmar, com um N/C de 95% que a média = 16.

TESTE DE HIPÓTESE

TESTE DE HIPÓTESE PARA A PROPORÇÃO (*P*)

Exemplo de aplicação

1. O consumidor de certo produto acusou o fabricante dizendo que mais de 20% das unidades fabricadas apresentam defeito. Para confirmar sua acusação ele usou uma amostra de tamanho 50, onde 25% das peças eram defeituosas, mostre como o fabricante poderia rejeitar a acusação, utilize α de 10%.

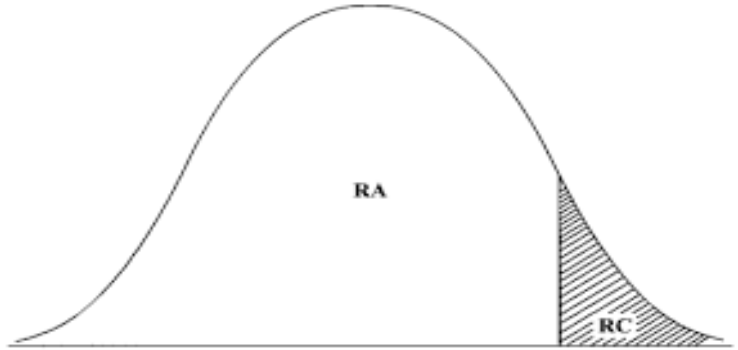
TESTE DE HIPÓTESE

TESTE DE HIPÓTESE PARA A PROPORÇÃO (*P*)

Ho: $P = 20\%$

H1: $P > 20\%$

$$Z(teste) = \frac{f - P}{\sqrt{\frac{P * q}{n}}} = \frac{0{,}25 - 0{,}20}{\sqrt{\frac{0{,}20 * 0{,}80}{50}}} = 0{,}88$$



Teste unicaudal

N/C = 90%

α = 10%

90% – 50% = 40%

Aceito H0, pois Z(teste) = 0,88 está na região de aceitação, afirmarmos, com N/C de 90%, que o consumidor não tem razão.